

Explicabilidad (XAI) aplicada a la concesion de credito

Construccion, optimizacion y auditoria de un modelo de scoring bajo dos politicas de coste

Oscar Romero Quincoces

Fernando Dapena Tauste

Daniel Garcia Lopez

Master MIAx – Bloque 4 – Practica B4-T2
20 de julio de 2026

Resumen

Se construye, optimiza y audita un modelo de concesion de credito sobre el conjunto *Give Me Some Credit* bajo dos matrices de coste: una simetrica ($C_{FP} = C_{FN} = 1$) y una asimetrica ($C_{FP} = 1$, $C_{FN} = 10$), en la que conceder credito a un cliente que impaga cuesta diez veces mas que denegarselo a uno solvente. El modelo final es un **XGBoost** supervisado, elegido por coste esperado en validacion cruzada frente a una regresion logistica, redes neuronales y un *bandit* contextual LinUCB. Un unico estimador sirve a ambos escenarios: solo se re-optimiza el umbral de decision, que cae de 0,4934 a 0,0906 y hace que la denegacion en produccion suba del 2,4 % al 18,5 %. La mejora del coste esperado respecto a conceder a todos pasa del 5,2 % (simetrico) al 51 % (asimetrico). El modelo se audita con un **arbol subrogado** (que revela “dos personalidades de riesgo” segun el umbral), **contrafactuales** accionables generados con DiCE, y valores **SHAP** globales y locales, contrastados frente a la inestabilidad de LIME. Un hallazgo del preprocesado — que la variable `DebtRatio` almacena el numerador de deuda sin dividir cuando falta el ingreso — se corrige y mejora la senal predictiva.

1. Datos y EDA

Se cargaron y validaron dos conjuntos: `cs_construccion.csv` (105 000 filas $\times$ 11 columnas, partición de entrenamiento, con la variable objetivo `SeriousDlqin2yrs`, 8,81 MB) y `cs_produccion.csv` (45 000 filas $\times$ 11 columnas, sin objetivo, 3,78 MB). Ambos se contrastaron contra el diccionario de datos del enunciado, comparando de forma sistemática *shapes*, tipos de dato (`dtype`) y porcentajes de nulos columna a columna. Sobre la partición de entrenamiento se caracterizó el desbalance de la variable objetivo, se detectaron valores centinela de codificación y outliers univariantes y multivariantes (mediante Isolation Forest), se calcularon matrices de correlación (Pearson y Spearman) y el Factor de Inflación de Varianza (VIF) por variable, y se cruzó la nulidad de `MonthlyIncome` y `NumberOfDependents` con el objetivo, con `DebtRatio` y con la edad para diagnosticar el mecanismo de ausencia. Finalmente, un análisis de robustez recalculó PCA, t-SNE y KernelPCA excluyendo las filas centinela y los outliers extremos, con el fin de comprobar si estas observaciones distorsionaban la estructura de los datos.

1.1. Validación del esquema: entrenamiento frente a producción

El esquema coincide en 10 de las 11 columnas; la única discrepancia es el `dtype` de la variable objetivo, que en producción aparece vacía y por tanto tipada como `float` (comportamiento esperado, no un error de carga). Los porcentajes de nulos son muy similares entre ambos conjuntos pero **no idénticos**: `MonthlyIncome` presenta 19,8048 % de nulos en entrenamiento frente a 19,8578 % en producción, y `NumberOfDependents` presenta 2,6076 % frente a 2,6356 %. Esta cercanía es consistente con que ambos conjuntos provienen del mismo proceso generador, lo que respalda la validez de ajustar cualquier transformación exclusivamente sobre entrenamiento y aplicarla después a producción sin reajuste.




Figura 1: Distribución de la variable objetivo `SeriousDlqin2yrs` en el conjunto de entrenamiento.

El desbalance de clases es manejable: 93,3162 % de los clientes (97 982 de 105 000) pertenecen a la clase 0 (no impago) y 6,6838 % (7018) a la clase 1 (impago), es decir, aproximadamente 1 de cada 15 clientes impaga. Este ratio permite abordar el desbalance en la fase de modelado mediante ajuste de umbral o ponderación de clase, sin necesidad de técnicas de remuestreo agresivas en

esta etapa exploratoria.

1.2. Valores centinela y outliers

Se identificaron valores centinela de codificación en las tres variables de morosidad (**NumberOfTime30-59DaysPastDueNotWorse**, **NumberOfTime60-89DaysPastDueNotWorse** y **NumberOfTimes90DaysLate**): los códigos 96 y 98 aparecen de forma simultánea en las tres columnas para el mismo registro, un patrón incompatible con conteos reales de incidencias y típico de una codificación de “dato no disponible” o “valor tope” heredada del sistema origen. Junto a estos centinelas se cuantificaron outliers univariantes por rango lógico y el resultado de un análisis multivariante con Isolation Forest.

Cuadro 1: Resumen de valores centinela y outliers detectados en el conjunto de entrenamiento (105 000 filas).

Hallazgo	<i>n</i> filas	% filas
NumberOfTime*PastDue* == 98 simultáneo en las 3 columnas	185	0,1762
NumberOfTime*PastDue* == 96 simultáneo en las 3 columnas	3	0,0029
age == 0 (edad inválida)	1	0,0010
RevolvingUtilizationOfUnsecuredLines > 2 (fuera de rango lógico de un ratio)	261	0,2486
DebtRatio > percentil 97,5 con MonthlyIncome nulo o ≤ 1 (posible artefacto de cálculo)	2625	2,5000

En conjunto, los 188 registros con centinela 96/98 (0,1790 % del total) muestran una tasa de impago del 54,26 %, ocho veces superior al 6,60 % del resto de la población, lo que descarta que se trate de ruido aleatorio de captura. La última fila de la tabla anticipa el hallazgo central del preprocesado (sección 4): 2625 filas (2,5000 % del total) combinan **DebtRatio** por encima del percentil 97,5 con **MonthlyIncome** no usable (nulo o ≤ 1), lo que apunta a un artefacto de cálculo -el numerador de deuda sin dividir- en lugar de variabilidad real del ratio.

1.3. Multicolinealidad: correlación y factor de inflación de varianza

Se calcularon las matrices de correlación de Pearson y de Spearman entre las diez variables explicativas, y el VIF de cada variable, definido para la variable j como

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 es el coeficiente de determinación de la regresión de la variable j sobre el resto de variables explicativas. Valores de $\text{VIF}_j > 10$ se consideran indicio de multicolinealidad severa.




Figura 2: Matriz de correlación de Pearson entre las variables explicativas del conjunto de entrenamiento.




Figura 3: Factor de Inflación de Varianza (VIF) por variable, conjunto de entrenamiento sin depurar.

Cuadro 2: VIF por variable en el conjunto de entrenamiento (antes de tratar los centinelas).

Variable	VIF
NumberOfTime60-89DaysPastDueNotWorse	92,30
NumberOfTimes90DaysLate	73,68
NumberOfTime30-59DaysPastDueNotWorse	41,29
NumberOfOpenCreditLinesAndLoans	1,29
NumberRealEstateLoansOrLines	1,27
age	1,09
NumberOfDependents	1,08
DebtRatio	1,02
MonthlyIncome	1,02
RevolvingUtilizationOfUnsecuredLines	1,00

El VIF severo (> 10) se concentra exclusivamente en las tres variables de morosidad (92,30, 73,68 y 41,29), y su origen está ligado a las 188 filas centinela descritas en la tabla 1 (0,1790 % del dataset): al calcular la correlación de Spearman -menos sensible a valores extremos que Pearson- entre esas mismas tres variables, el coeficiente cae a un rango de 0,25-0,32, muy por debajo del 0,98-0,99 que arroja Pearson sobre los datos sin depurar. Esta discrepancia confirma que la multicolinealidad aparente es en gran medida un artefacto de un número reducido de observaciones con codificación centinela, no una relación lineal genuina y estable entre las tres variables.

1.4. Mecanismo de ausencia en MonthlyIncome y NumberOfDependents

Para diagnosticar el mecanismo de ausencia de las dos variables con nulos relevantes se cruzó su indicador de nulidad con el objetivo, con DebtRatio y con la edad.




Figura 4: Tasa de impago según la nulidad de MonthlyIncome.




Figura 5: Distribución de DebtRatio según la nulidad de MonthlyIncome.

El resultado es contraintuitivo: el grupo con **MonthlyIncome** nulo presenta una tasa de impago del 5,4917 %, frente al 6,9782 % del grupo con ingreso conocido -1,4865 puntos porcentuales menos-, pese a lo cual la diferencia es sistemática y no aleatoria. Además, **DebtRatio** guarda en las filas de ingreso no usable el numerador crudo de deuda sin dividir: la mediana en ese subgrupo es 1181,0 frente a 0,2953 en el subgrupo con ingreso conocido (3999,32 veces mayor), y el 93,912 % de esas filas presenta **DebtRatio** > 1, frente a solo el 6,0151 % en el resto -evidencia de un artefacto de cálculo, no de variabilidad real del ratio-. El nulo de **NumberOfDependents** (2738 filas, 2,6076 % del total) es además subconjunto exacto (100 %) del nulo de **MonthlyIncome**; ese subgrupo conjunto es sistemáticamente más mayor (edad mediana 61 frente a 52 años) y con menor tasa de impago (4,6749 % frente a 6,7376 %). El conjunto de evidencias -sistematicidad, asociación con la edad y con el propio valor de **DebtRatio**- es compatible con un mecanismo de ausencia MNAR (*missing not at random*): clientes de mayor edad con menos datos financieros registrados, no un fallo de captura independiente del valor no observado.

1.5. Análisis de robustez

Con el fin de comprobar si las filas centinela y los outliers extremos distorsionaban la estructura geométrica de los datos, se recalcularon PCA, t-SNE y KernelPCA excluyendo dichas observaciones. La separación entre clases en las proyecciones resultantes no mejora al eliminarlas, lo que indica que el efecto de los centinelas se limita a las métricas de correlación y VIF (sección anterior) y no a la estructura real subyacente de los datos; en consecuencia, no se justifica eliminar estas filas del conjunto de entrenamiento, sino tratarlas explícitamente como valores faltantes en el preprocesado (sección 4).

Hallazgos

- Desbalance manejable (aproximadamente 1 de cada 15 clientes en clase 1): 93,3162 % clase 0 (97 982 filas) frente a 6,6838 % clase 1 (7018 filas).
- Esquema y nulos casi idénticos entre entrenamiento y producción, con una única diferencia esperada (**dtype** del objetivo, vacío en producción): **MonthlyIncome** 19,8048 % (entrena-

miento) frente a 19,8578 % (producción); **NumberOfDependents** 2,6076 % frente a 2,6356 % -parecidos, no idénticos-.

- **DebtRatio** guarda el numerador crudo de deuda sin dividir cuando falta **MonthlyIncome**: mediana 1181,0 frente a 0,2953 con ingreso conocido (3999,32 veces mayor), y 93,912 % de esas filas presenta **DebtRatio** > 1 frente a solo 6,0151 % en el resto: es un artefacto de cálculo, no variabilidad real.
- Hallazgo contraintuitivo: el nulo de **MonthlyIncome** NO marca mayor riesgo -tasa de impago 5,4917 % (nulo) frente a 6,9782 % (conocido), 1,4865 puntos menos-, aunque la diferencia es sistemática (no aleatoria): mejor preservarla con una variable indicadora que imputar y perder la señal.
- El nulo de **NumberOfDependents** (2738 filas, 2,6076 %) es subconjunto exacto (100 %) del nulo de **MonthlyIncome**; ese subgrupo es más mayor (edad mediana 61 frente a 52 años) y con menor tasa de impago (4,6749 % frente a 6,7376 %): ambos nulos comparten un mismo mecanismo de ausencia MNAR, compatible con clientes mayores con menos datos financieros registrados.
- VIF severo (> 10) solo en las tres columnas de morosidad (92,30 / 73,68 / 41,29), inflado por 188 filas centinela (96 o 98 simultáneo en las tres columnas, 0,1790 % del dataset) con tasa de impago del 54,26 % -ocho veces el 6,60 % del resto-: la correlación de Spearman real cae a un rango de 0,25-0,32, muy por debajo del 0,98-0,99 de Pearson sobre los datos sin depurar.
- El análisis de robustez (PCA, t-SNE y KernelPCA recalculados sin los centinelas ni los outliers extremos) confirma que la separación entre clases no mejora al eliminarlos: el efecto de los centinelas recae sobre las métricas de correlación y VIF, no sobre la estructura real de los datos.
- Recomendación de imputación derivada del EDA: **MonthlyIncome** por mediana condicionada al tramo de edad (2800,0 en clientes de 30 años o menos frente a 6307,0 en el tramo 51-60, frente a 5400,0 de mediana global) más variable indicadora de ausencia; **NumberOfDependents** por moda/mediana global (0) con su propia variable indicadora.

2. Preprocesado

Antes de aprender ningún parámetro se realizó una partición 80/20 estratificada (**random_state=42**) del conjunto de entrenamiento **cs_construccion.csv**: 84 000 filas para entrenamiento y 21 000 para test, con tasas de clase positiva casi idénticas entre sí (6.6833 % y 6.6857 %) y muy próximas a la tasa global del conjunto completo (6.6838 %, a solo 0.0024 puntos porcentuales de distancia). Todo lo que sigue -limpieza, imputación, recálculo de variables, winsorizado y escalado- se ajusta únicamente sobre las 84 000 filas de entrenamiento, nunca sobre test ni sobre producción, para evitar fuga de información.

Cuadro 3: Resumen de la partición train/test sobre **cs_construccion.csv**.

Conjunto	<i>n</i> filas	<i>n</i> positivos	<i>n</i> negativos	Tasa clase 1
Train	84 000	5 614	78 386	0.0668
Test	21 000	1 404	19 596	0.0669
Total	105 000	7 018	97 982	0.0668

El orden real de las transformaciones sobre train es: (i) se limpia **age** (1 fila con **age==0**); (ii) se tratan como valores perdidos los códigos centinela 96/98 simultáneos en las tres columnas

de morosidad (149 filas, 0.1774% del train); (iii) se imputa `MonthlyIncome` por la mediana del tramo de edad, excluyendo las filas de ingreso no usable; y (iv) se imputa `NumberOfDependents` por su moda (0). El desbalance de clases (6.68%) no se corrige en esta fase: remuestrear antes de fijar el modelo introduciría fuga de información entre el ajuste de parámetros y la evaluación, de modo que se delega a la fase de modelado mediante `class_weight` o ajuste del umbral de decisión por coste.

2.1. Hallazgo central: recálculo del ratio de deuda (`DebtRatio`)

El hallazgo analítico central del preprocesado es que el fichero de origen almacena, cuando el ingreso mensual no es utilizable, el **numerador crudo de deuda** en la columna `DebtRatio` en lugar del ratio propiamente dicho. Se define como ingreso no usable la unión de dos subgrupos: ingreso nulo o ingreso ≤ 1 . Sobre train, `income_no_usable` comprende 17 900 filas (21.3095%): 16 695 nulos más 1 205 con ingreso ≤ 1 . Un contraste χ^2 entre ambos subgrupos frente al objetivo arroja $\chi^2 = 6.8716$, $p = 0.008758$: son estadísticamente distintos entre sí en tasa de riesgo. Aun así, se fusionan en un único indicador `is_missing_monthlyincome`, porque lo que comparten no es la tasa de riesgo sino el mismo mecanismo de corrupción del numerador de deuda; es una decisión de honestidad metodológica -reconocer que la fusión no es estadísticamente perfecta- y no un atajo de conveniencia.

La corrección aplicada a las filas de `income_no_usable` es

$$\text{DebtRatio}_{\text{corregido}} = \frac{\text{DebtRatio}_{\text{crudo}}}{\text{MonthlyIncome}_{\text{imputado}}},$$

es decir, se divide el numerador de deuda ya almacenado por el ingreso mensual una vez imputado (sección 2.2), transformando un valor que hoy tiene unidades de moneda en un ratio adimensional comparable al del resto de la población.




Figura 6: Distribución de `DebtRatio` en las filas de ingreso no usable antes (numerador crudo sin dividir) y después (dividido por el ingreso ya imputado) del recálculo, frente al rango de la población con ingreso conocido.

Cuadro 4: Métricas de validación del recálculo de `DebtRatio`.

Métrica	Valor
n <code>income_no_usable</code>	17 900
Mediana <code>DebtRatio</code> no usable (ANTES)	1152.0000
Mediana <code>DebtRatio</code> usable	0.2902
Ratio de medianas	3969.4631
Umbral percentil 97.5 de <code>DebtRatio</code>	3538.0250
n cola > percentil 97.5	2100
% cola que es <code>income_no_usable</code>	100.0000
Mediana <code>DebtRatio</code> no usable (DESPUÉS)	0.2050
KS antes del recálculo	0.9284
KS después del recálculo	0.1671
n filas recalculadas	17 900

El estadístico de Kolmogorov-Smirnov de dos muestras,

$$D = \sup_x |F_{\text{contaminada}}(x) - F_{\text{sana}}(x)|,$$

comparando la distribución de `DebtRatio` en las filas afectadas frente al resto de la población, cae de $D = 0.9284$ antes del recálculo a $D = 0.1671$ después: las dos distribuciones pasan de ser casi disjuntas a solaparse de forma sustancial. Como consecuencia, el poder predictivo univariante de `DebtRatio` frente al objetivo -medido en AUC de un modelo de una sola variable- sube de 0.5212 (prácticamente sin señal) a 0.5531 tras la corrección. La mediana de `DebtRatio` en las filas no usables pasa de 1152.0 (antes, frente a 0.2902 en las filas usables, un factor de ~ 3970) a 0.2050 (después, ya comparable a la población general); adicionalmente, el 100 % de las 2 100 filas situadas por encima del percentil 97.5 (umbral 3538.0250) antes del recálculo correspondía a `income_no_usable`, confirmando que esa cola era un artefacto de cálculo y no variabilidad real del ratio de deuda.

2.2. Imputación de `MonthlyIncome` y `NumberOfDependents`

`MonthlyIncome` se imputa por la mediana condicionada al tramo de edad del solicitante, no por la mediana global: la mediana global habría colapsado las 17 900 filas con ingreso no usable a un único valor (5460.0), generando un pico artificial en la distribución e ignorando el patrón real -en forma de U invertida- del ingreso mediano por tramo de edad.




Figura 7: Mediana de `MonthlyIncome` por tramo de edad frente al valor único que resultaría de imputar por la mediana global.

Cuadro 5: Parámetros de imputación aprendidos sobre train.

Parámetro	Valor
Mediana de <code>age</code>	52.0
Mediana income, tramo ≤ 30 años	2959.0
Mediana income, tramo 31-40 años	5000.0
Mediana income, tramo 41-50 años	6167.0
Mediana income, tramo 51-60 años	6400.0
Mediana income, tramo 61-70 años	5907.5
Mediana income, tramo > 70 años	4526.0
Mediana income global	5460.0
Moda de <code>NumberOfDependents</code>	0.0

`NumberOfDependents` se imputa por su moda (0), coherente con el hallazgo de la fase de EDA de que su nulidad es subconjunto exacto del de `MonthlyIncome` y comparte el mismo mecanismo de ausencia. Todos los parámetros de imputación -medianas por tramo de edad, mediana global y moda- se aprenden exclusivamente sobre train y se congelan dentro del objeto `PreprocesadorCredito` para aplicarse sin reajuste a test y a producción.

2.3. Winsorizado, transformación logarítmica y escalado

Tras la imputación y el recálculo de `DebtRatio`, el pipeline aplica winsorizado seguido de transformación logarítmica y estandarización. El winsorizado recorta cada variable a su percentil superior empírico,

$$x_{\text{winsor}} = \min(x, q_p),$$

donde q_p es el percentil p estimado sobre train. `RevolvingUtilizationOfUnsecuredLines` se recorta al percentil 99 ($\text{cap} = 1.102904$) y `DebtRatio` al percentil 99.9 ($\text{cap} = 9.184215$), antes de aplicar la transformación logarítmica $x' = \log(1 + x)$ ($\log 1p$) y, finalmente, el escalado estándar

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}},$$

con μ_{train} y σ_{train} estimados una única vez sobre train y reutilizados sin reajuste en test y producción.

El winsorizado no es redundante con el $\log 1p$: sobre `RevolvingUtilizationOfUnsecuredLines`, el sesgo (*skewness*) crudo de 63.10 solo baja a 11.65 aplicando $\log 1p$ sin recorte previo -insuficiente-, mientras que la combinación winsor+ $\log 1p$ lo reduce a 0.72. `age`, en cambio, queda deliberadamente excluida de la transformación logarítmica: su sesgo crudo (0.1909, ya próximo a la simetría) empeoraría a -0.4346 si se le aplicara $\log 1p$. Los sesgos finales tras el pipeline completo son: `Revolving` 0.717, `DebtRatio` 2.3282, `MonthlyIncome` -0.6159 y `age` 0.1909.




Figura 8: Distribución de `RevolvingUtilizationOfUnsecuredLines` antes del recorte (cola larga extrema) frente a después de winsorizado + $\log 1p$ + escalado (forma casi simétrica).

2.4. Multicolinealidad tras el tratamiento de los centinelas

El VIF severo de las tres variables de morosidad, detectado en la fase de EDA sobre los datos sin depurar (40.90, 71.70 y 89.64), es en gran parte un artefacto de las 149 filas centinela (códigos 96/98 simultáneos en las tres columnas), entre las que la correlación de Pearson máxima llega a 0.9926. Al tratar estos centinelas como valores perdidos en el preprocesado, el VIF de las tres variables colapsa a 1.18, 1.15 y 1.17, y la correlación de Pearson máxima entre ellas baja a 0.2995, recordando que

$$\text{VIF}_j = \frac{1}{1 - R_j^2}.$$

Las tres variables pueden por tanto incorporarse al modelo como *features* independientes, sin necesidad de consolidarlas en un índice compuesto. El VIF máximo de todas las variables del pipeline final es 1.9065, correspondiente a `DebtRatio`, sin indicios de multicolinealidad relevante.

Cuadro 6: VIF por variable, antes (datos sin depurar) y después del tratamiento de centinelas en el pipeline final.

Variable	VIF antes	VIF después
<code>RevolvingUtilizationOfUnsecuredLines</code>	1.0006	1.2498
<code>age</code>	1.0844	1.1709
<code>NumberOfTime30-59DaysPastDueNotWorse</code>	40.8977	1.1781
<code>DebtRatio</code>	1.0240	1.9065
<code>MonthlyIncome</code>	1.0160	1.5578
<code>NumberOfOpenCreditLinesAndLoans</code>	1.2860	1.4221
<code>NumberOfTimes90DaysLate</code>	71.6977	1.1494
<code>NumberRealEstateLoansOrLines</code>	1.2755	1.8750
<code>NumberOfTime60-89DaysPastDueNotWorse</code>	89.6394	1.1720
<code>NumberOfDependents</code>	1.0787	1.1171

2.5. Contrato de salida y verificación de fuga de información

El pipeline entrega tres tablas: train ($84\,000 \times 13$), test ($21\,000 \times 13$) y producción ($45\,000 \times 14$, con la columna adicional `id_fila_original` para trazabilidad). Cada tabla contiene 10 variables continuas en `float64` más 2 indicadores en `int8` (`is_missing_monthlyincome` y `es_centinela_pastdue`). Una batería de 9 aserciones automáticas (A-I) certifica el contrato antes de dar el pipeline por válido:

- Reproducibilidad exacta del objeto serializado (tolerancia `atol = 0`).
- Esquema de columnas y ausencia total de valores `NaN`.
- Conteo de filas correcto en cada partición.
- Apatridia por lote: procesar una fila aislada o el lote completo produce el mismo resultado fila a fila (tolerancia `atol = 10^{-12}`).
- El ajuste (`fit`) usó exclusivamente train, nunca test ni producción.
- Invarianza al orden de las filas de entrada (permutar el orden no altera el resultado).
- Robustez ante valores de producción no vistos en train -por ejemplo, un valor de `RevolvingUtilizationOfUnsecuredLines` = 50708 se recorta correctamente al cap de entrenamiento, 1.102904-.
- Idempotencia al releer el objeto `PreprocesadorCredito` guardado en disco.




Figura 9: Media absoluta de las variables preprocesadas por conjunto: train, test y producción.

La comprobación más directa de ausencia de fuga es la media absoluta de las variables ya escaladas en cada conjunto: en train se sitúa en $\sim 6.83 \times 10^{-16}$ -esencialmente cero de máquina, como corresponde a un escalado estándar ajustado sobre los mismos datos-, frente a 0.021086 en test y 0.014083 en producción. El salto de aproximadamente 14 órdenes de magnitud entre train y los otros dos conjuntos es la evidencia empírica de que el ajuste del escalador no vio ni test ni producción durante el `fit`.

Hallazgos

- El split preserva el desbalance real de clases: 84 000 filas de train frente a 21 000 de test, con tasas de clase positiva de 6.6833 % y 6.6857 % (0.0024 puntos porcentuales de diferencia); el indicador `es_centinela_pastdue` dispara la tasa del objetivo hasta 53.69 %, frente a 6.60 % en el resto de la población (~ 8 veces), evidencia de que no es ruido de captura.
- El recálculo de `DebtRatio` confirma la hipótesis planteada en el EDA: el estadístico KS pasa de 0.9284 a 0.1671, el AUC univariante de 0.5212 a 0.5531, y la mediana de las filas no usables de 1152.0 a 0.2050 tras dividir por el ingreso ya imputado.
- El VIF de las tres variables de morosidad cae de 40.90/71.70/89.64 a ~ 1.2 al tratar como perdidas las 149 filas centinela; el VIF máximo de todo el conjunto final de variables es 1.9065 (`DebtRatio`), sin indicios de multicolinealidad relevante.
- La auditoría de fuga muestra una media absoluta de las variables de $\sim 6.83 \times 10^{-16}$ en train frente a 0.021086 en test y 0.014083 en producción -un salto de ~ 14 órdenes de magnitud-, reforzada por 9 aserciones (A-I) que incluyen apatridia por lote e invarianza a la permutación del orden de las filas.
- Nota de calidad de datos: 107 filas de test (0.51 %) tienen una fila “gemela” exacta en train (idénticas en las 10 variables originales y en el objetivo); el impacto práctico en el escenario de coste simétrico es prácticamente nulo, pero se deja constancia explícita de la existencia de duplicados repartidos entre particiones.
- Decisión explícita de diseño: el desbalance de clases (6.68 %) no se corrige en el preprocesado, porque remuestrear antes de fijar el modelo constituiría fuga de información; se delega a la fase de modelado mediante `class_weight` o ajuste del umbral de decisión por coste (secciones 5 y 6).

3. Modelo: escenario de coste simétrico ($C_{FP} = C_{FN} = 1$)

3.1. Planteamiento y convención de costes

La convención de coste queda fijada sin ambigüedad antes de entrenar ningún modelo. Se define como clase positiva el impago (`SeriousDlqin2yrs=1`); una predicción $\hat{y} = 1$ significa *denegar* el crédito y $\hat{y} = 0$ significa *concederlo*. En este marco, un falso negativo (FN) equivale a conceder crédito a un solicitante que después impaga –el error caro desde el punto de vista del negocio–, mientras que un falso positivo (FP) equivale a denegar crédito a un buen pagador. Los aciertos (TP y TN) no generan coste. En este primer escenario ambos tipos de error se penalizan por igual: $C_{FP} = C_{FN} = 1$.

Se comparan cinco familias de modelos con interfaz común `predict/predict_proba`: regresión logística, XGBoost, una red neuronal pequeña (MLP), una red neuronal profunda (MLP) y un bandit contextual LinUCB. Ninguna de ellas reponde las clases (sin *SMOTE* ni `class_weight`): bajo una matriz de coste asimétrica la respuesta metodológicamente correcta es desplazar el **umbral** de decisión aplicado a la probabilidad estimada, no distorsionar la probabilidad misma alterando el proceso de entrenamiento.

3.2. Metodología: validación cruzada, probabilidades OOF y umbral óptimo

La comparación de familias y la búsqueda del umbral se realizan con validación cruzada estratificada de 5 particiones (folds) sobre el conjunto de entrenamiento, utilizando siempre las probabilidades *out-of-fold* (OOF) concatenadas de las 84 000 observaciones de train –nunca las de test–, precisamente para evitar fuga de información: optimizar el umbral directamente sobre test contaminaría la misma cifra que después se reporta como resultado final.

El coste esperado empírico para un umbral θ se define como el coste medio por solicitante:

$$\text{Coste}(\theta) = \frac{1}{n} \sum_{i=1}^n \left[C_{FP} \cdot \mathbf{1}(y_i = 0, \hat{y}_i(\theta) = 1) + C_{FN} \cdot \mathbf{1}(y_i = 1, \hat{y}_i(\theta) = 0) \right]$$

donde $\hat{y}_i(\theta) = \mathbf{1}(p_i \geq \theta)$ y p_i es la probabilidad de impago estimada para el solicitante i . El umbral operativo se obtiene por búsqueda exhaustiva (*argmin*) del coste sobre las probabilidades OOF:

$$\theta_{\text{OOF}}^* = \arg \min_{\theta \in [0,1]} \text{Coste}(\theta)$$

y se contrasta con el umbral óptimo analítico, que se deriva minimizando el coste esperado bajo la probabilidad estimada e iguala el coste marginal de ambos tipos de error:

$$\theta^* = \frac{C_{FP}}{C_{FP} + C_{FN}}$$

que para el escenario simétrico da $\theta^* = 1/2 = 0.5$. Al no producir una probabilidad calibrada ni un umbral explícito, LinUCB se evalúa por su acción *greedy* OOF (denegar si la recompensa esperada de conceder es negativa). El modelo ganador se reentrena sobre el 100 % de train con su umbral de validación cruzada y se evalúa una única vez sobre el conjunto de test, frente a dos referencias triviales: conceder crédito a todos los solicitantes y denegarlo a todos.

3.3. Comparación de familias por validación cruzada

Cuadro 7: Comparación de familias de modelos por coste esperado en CV(5) sobre probabilidades OOF.

Familia	Modelo	Coste CV	Umbral	AUC	Tasa denegación CV
Boosted	XGBoost	0.0623	0.4934	0.8642	0.0233
Neuronal	MLP pequeña	0.0624	0.4891	0.8617	0.0201
Neuronal	MLP profunda	0.0626	0.4759	0.8630	0.0185
Lineal	Logística	0.0629	0.4837	0.8515	0.0205
Bandit	LinUCB	0.0629	N/D	N/D	0.0214
Baseline	Conceder-todo	0.0668	N/D	N/D	0.0000
Baseline	Denegar-todo	0.9332	N/D	N/D	1.0000




Figura 10: Coste esperado OOF en función del umbral de decisión. La curva es notablemente plana en el entorno del óptimo empírico ($\theta_{\text{OOF}}^* = 0.4934$), que cae muy cerca de la vertical analítica $\theta^* = 0.5$.




Figura 11: Distribución de la probabilidad de impago estimada, $P(\text{impago})$, según la clase real en test. El solapamiento sustancial entre ambas clases alrededor del umbral explica por qué el coste global resulta bajo aunque el *recall* también lo sea.




Figura 12: Coste en test por familia de modelo (el ganador, XGBoost, destacado), frente a la línea punteada del baseline de conceder-todo.

Hallazgos de la selección de modelo (CV(5), OOF)

- Gana XGBoost con $\text{coste}_{CV} = 0.062286$, seguido de cerca por MLP pequeña (0.062440), MLP profunda (0.062619), logística (0.062917) y LinUCB (0.062929). La familia de modelo casi no importa en este escenario: el margen entre logística y XGBoost es de solo 0.000631, dentro del ruido de estimación.
- El umbral óptimo empírico OOF, $\theta_{OOF}^* = 0.493394$, es prácticamente idéntico al óptimo analítico $\theta^* = 0.5$, lo que confirma la teoría y revela una curva de coste casi degenerada: este es un escenario poco exigente para discriminar entre familias (el escenario informativo es el asimétrico, tratado en la sección siguiente).

- A igual capacidad *lineal*, LinUCB (bandit) prácticamente empata con la regresión logística (0.062929 frente a 0.062917): el bandit no resulta inferior al aprendizaje supervisado cuando ambos compiten con la misma capacidad de modelo. La ventaja de XGBoost procede de su *capacidad* (boosting de árboles), no del mero hecho de ser supervisado. Se elige el modelo supervisado por auditabilidad y calibración –probabilidad interpretable, sin el *regret* de exploración propio de un bandit– y no por una superioridad intrínseca del paradigma.

3.4. Umbral óptimo, evaluación en test y matriz de confusión

Cuadro 8: Síntesis del modelo ganador (XGBoost) en el escenario de coste simétrico.

Métrica	Valor
Umbral óptimo (OOF)	0.4934
Umbral analítico (θ^*)	0.5000
Coste CV	0.0623
Coste test	0.0634
Coste conceder-todo	0.0669
Coste denegar-todo	0.9331
Mejora relativa vs. conceder-todo	5.20 %

Cuadro 9: Matriz de confusión en test con el umbral óptimo $\theta_{\text{OOF}}^* = 0.4934$.

	Predicho: conceder	Predicho: denegar
Real: buen pagador	19 383	213
Real: moroso	1 118	286




Figura 13: Matriz de confusión en test (mapa de calor) con el umbral óptimo del escenario simétrico. Los falsos negativos (1 118) superan con creces a los falsos positivos (213), coherente con la precisión y el *recall* obtenidos.

Hallazgos de test y producción

- En test, el coste alcanzado por el modelo ganador es 0.063381, frente a 0.066857 del baseline de conceder-todo (mejora relativa de 5.1994 %) y muy por debajo de 0.933143 del baseline de denegar-todo.
- Métricas de contexto del ganador en test –no determinan el umbral, se reportan como referencia–: precisión = 0.573146, *recall* = 0.203704, AUC = 0.870109. Matriz de confusión cruda: $TN = 19\,383$, $FP = 213$, $FN = 1\,118$, $TP = 286$.
- Un *bootstrap* pareado ($B = 5000$, semilla 42) del margen (*edge*) del ganador frente a conceder-todo da un *edge* medio de 0.003476 (5.20 % del coste del baseline), con intervalo de confianza al 95 % de [0.001381, 0.005571] y $P(\text{edge} \leq 0) = 0.0008$: la mejora es pequeña en términos absolutos pero estadísticamente significativa.
- La transferencia de test a producción se verifica con un tamaño de efecto de Kolmogorov–Smirnov $D = 0.011800$ (despreciable) entre las distribuciones de $P(\text{impago})$ en ambos conjuntos, medias muy próximas (0.068223 en test frente a 0.067049 en producción) y tasas de denegación casi idénticas (0.023762 frente a 0.023556, diferencia 0.000206): el *scoring* generaliza sin desplazamiento material, bajo el supuesto –no verificable sin etiquetas– de que la prevalencia real en producción se mantiene estable.
- El entregable oficial `cs_produccion1.csv` (45 000 filas) se verifica con 5 comprobaciones bloqueantes (*asserts*): objetivo en $\{0, 1\}$ sin valores nulos, columnas y orden originales preservados, y cobertura exacta de índices 0 a 44 999. La tasa de denegación en producción es del 2.3556 % (1 060 de 45 000 solicitantes), coherente con un escenario de coste simétrico que deniega poco.

4. Modelo – escenario de coste asimétrico ($C_{FN} = 10 \cdot C_{FP}$)

4.1. Planteamiento y reutilización del modelo

En este escenario un falso negativo (conceder crédito a un solicitante que posteriormente impaga) se penaliza diez veces más que un falso positivo (denegar crédito a un buen pagador): $C_{FP} = 1$, $C_{FN} = 10$. No se reentrena ningún modelo nuevo: se reutiliza el mismo XGBoost ganador del escenario simétrico (sección anterior) junto con las mismas 84 000 probabilidades *out-of-fold* (OOF) de entrenamiento, con coincidencia byte a byte verificada frente al escenario simétrico. Bajo una matriz de coste asimétrica no es necesario alterar el modelo probabilístico subyacente: basta con desplazar el **umbral de decisión** que convierte la probabilidad estimada de impago, $\hat{p}_i = \hat{P}(y_i = 1 | x_i)$, en una decisión binaria de conceder/denegar. De este modo, un único modelo con dos umbrales distintos cubre ambos escenarios de negocio.

La regla de decisión parametrizada por el umbral θ es

$$\hat{y}_i(\theta) = \mathbf{1}(\hat{p}_i \geq \theta), \quad \hat{y}_i = 1 \Rightarrow \text{denegar}, \quad \hat{y}_i = 0 \Rightarrow \text{conceder},$$

y el coste esperado empírico asociado a un umbral θ , evaluado sobre un conjunto de N observaciones con etiqueta real y_i , es

$$\text{Coste}(\theta) = \frac{1}{N} \sum_{i=1}^N \left[C_{FP} \cdot \mathbf{1}(y_i = 0, \hat{y}_i(\theta) = 1) + C_{FN} \cdot \mathbf{1}(y_i = 1, \hat{y}_i(\theta) = 0) \right].$$

El umbral óptimo empírico se obtiene por búsqueda exhaustiva (argmín) de esta función sobre las probabilidades OOF de entrenamiento, evitando por construcción cualquier fuga de información desde el conjunto de test. Ese umbral empírico se contrasta con el óptimo analítico derivado de igualar el coste marginal esperado de ambas clases de error,

$$\theta^* = \frac{C_{FP}}{C_{FP} + C_{FN}}.$$

Con $C_{FP} = 1$ y $C_{FN} = 10$, el umbral analítico teórico es $\theta^* = 1/11 = 0.0909$.

4.2. Umbral óptimo y coste esperado

El umbral óptimo empírico cae de 0.4934 (escenario simétrico) a **0.0906** en el escenario asimétrico, prácticamente coincidente con el 0.0909 analítico. La Figura 14 contrasta ambos escenarios y la Figura 15 muestra la curva de coste OOF frente al umbral con el óptimo empírico marcado.




Figura 14: Comparación del escenario simétrico y el escenario asimétrico sobre el mismo modelo XGBoost: cambia únicamente el umbral de decisión aplicado a la misma probabilidad estimada.




Figura 15: Coste esperado OOF en función del umbral de decisión, escenario $C_{FN} = 10 \cdot C_{FP}$. El mínimo empírico (umbral 0.0906) queda prácticamente sobre la vertical analítica teórica ($1/11 = 0.0909$).

Cuadro 10: Resultados del escenario asimétrico (`coste10`) para el modelo XGBoost ganador, umbral fijado por validación cruzada sobre probabilidades OOF y evaluado una única vez en test.

Métrica	Valor
Umbral óptimo (empírico, CV)	0.0906
Umbral óptimo (analítico, $C_{FP}/(C_{FP} + C_{FN})$)	0.0909
Coste esperado (CV, OOF train)	0.3344
Coste esperado (test)	0.3275
Coste del baseline “conceder-todo”	0.6686
Tasa de denegación (test)	18.70 %
Mejora relativa vs. conceder-todo	51.01 %

El mínimo de la curva de coste es notablemente plano: la diferencia de coste entre operar con el umbral analítico teórico (0.0909) y con el umbral empírico (0.0906) es de apenas ~ 0.0008 . Esto es coherente con la buena calibración del modelo justo en la banda de decisión: para probabilidades predichas en el intervalo $[0.08, 0.12]$, la media predicha (~ 0.0968) se aproxima razonablemente a la tasa real de impago observada en ese mismo tramo (~ 0.0996).

4.3. ¿Es el mismo modelo el mejor bajo asimetría?

Además de reoptimizar el umbral, se recompensa por validación cruzada la familia de modelos –regresión logística, XGBoost y bandit contextual LinUCB (este último reentrenado con la nueva recompensa asimétrica)– bajo la matriz de coste $C_{FP} = 1$, $C_{FN} = 10$, para comprobar si la asimetría cambia quién gana (Tabla 11, Figura 16).

Cuadro 11: Comparación de familias de modelos bajo el escenario asimétrico ($C_{FP} = 1$, $C_{FN} = 10$), coste por validación cruzada (CV) sobre probabilidades OOF.

Familia	Modelo	Coste (CV)	Tasa denegación (CV)	Mejora vs. conceder-todo
Boosted	XGBoost	0.3344	18.37 %	49.97 %
Bandit	LinUCB	0.3502	16.64 %	47.60 %
Lineal	Logística	0.3513	18.04 %	47.43 %
Baseline	Conceder-todo	0.6683	0.00 %	0.00 %
Baseline	Denegar-todo	0.9332	100.00 %	-39.63 %




Figura 16: Coste por familia de modelo bajo el escenario asimétrico. A diferencia del escenario simétrico, aquí la familia de modelo sí importa.

A diferencia del escenario simétrico –donde el margen entre familias era de solo ~ 0.0006 y prácticamente irrelevante–, bajo asimetría XGBoost (coste CV = 0.3344) supera a la regresión logística (0.3513) y al bandit LinUCB (0.3502) por un margen de 0.0170, un orden de magnitud mayor. El bandit LinUCB iguala aproximadamente a la regresión logística (ambos de capacidad lineal), lo que indica que la ventaja de XGBoost proviene de su mayor capacidad de modelado (boosting de árboles), no del mero hecho de ser un método supervisado frente a un bandit.

4.4. Efecto sobre la matriz de confusión y sobre la producción

Encarecer el falso negativo desplaza fuertemente el punto de operación del modelo hacia la denegación preventiva (Figura 17). En el conjunto de test (21 000 solicitudes), los falsos negativos bajan de 1118 (escenario simétrico) a **396**, mientras que los falsos positivos suben de 213 a **2918**: el trasvase exacto que impone penalizar diez veces más conceder crédito a un moroso. Con el umbral asimétrico el modelo alcanza en test una precisión de 0.2568 y un recall de 0.7179, frente a 0.5731 y 0.2037 respectivamente en el escenario simétrico. El Área Bajo la Curva ROC (AUC) se mantiene idéntica, 0.8701, en ambos escenarios: es la prueba directa de que solo cambia el punto de corte sobre la misma probabilidad estimada, no el modelo subyacente.




Figura 17: Matrices de confusión en test, escenario simétrico frente a escenario asimétrico: los falsos negativos caen de 1118 a 396 y los falsos positivos suben de 213 a 2918.

Consecuentemente, la tasa de denegación en test sube de 2.38 % a 18.70 %. Aplicando el mismo umbral asimétrico sobre las 45 000 solicitudes del conjunto de producción (sin etiqueta observable), la tasa de denegación pasa de 2.36 % (1060 solicitantes) a 18.53 % (8339 solicitantes): 7279 solicitantes cambian de concedido a denegado y ninguno en sentido inverso, porque el umbral asimétrico es estrictamente más bajo que el simétrico y, por construcción, sus denegaciones incluyen a todas las del escenario simétrico.

4.5. Hallazgos

- El umbral óptimo empírico (0.0906) casi coincide con el analítico teórico $1/11 = 0.0909$: el modelo está bien calibrado justo en la banda de decisión (probabilidad predicha ~ 0.0968 frente a tasa real de impago ~ 0.0996 en el intervalo $[0.08, 0.12]$); además el mínimo de coste es plano, con solo ~ 0.0008 de diferencia entre usar el umbral analítico o el empírico.
- Bajo asimetría el modelo aporta un valor de negocio sustancialmente mayor: el coste en test baja de 0.6686 (conceder-todo) a 0.3275, una mejora relativa del 51.01 %, muy por encima del 5.20 % logrado en el escenario simétrico, y ambos muy por debajo del coste de denegar-todo (0.9331).
- Aquí la familia de modelo sí importa: XGBoost (coste CV = 0.3344) bate a la regresión logística (0.3513) y al bandit LinUCB (0.3502) por un margen de 0.0170, muy superior al ~ 0.0006 que separaba a las familias en el escenario simétrico; el bandit iguala aproximadamente a la logística (misma capacidad lineal), lo que sitúa la ventaja de XGBoost en su capacidad de boosting y no en el paradigma supervisado *per se*.
- La matriz de confusión en test se reequilibra al encarecer el falso negativo: los falsos negativos bajan de 1118 a 396 y los falsos positivos suben de 213 a 2918; el modelo ganador alcanza precisión = 0.2568, recall = 0.7179 y AUC = 0.8701 (el AUC no cambia porque el scoring es el mismo; solo cambia el punto de corte).
- La tasa de denegación sube de 2.38 % a 18.70 % en test y, aplicando el mismo umbral en producción, de 2.36 % (1060 de 45 000) a 18.53 % (8339 de 45 000): 7279 solicitantes pasan de concedido a denegado y ninguno en sentido inverso, consecuencia directa de que el umbral asimétrico es estrictamente más bajo que el simétrico.

5. Tabla comparativa de resultados entre ambos escenarios

Esta sección consolida y contrasta, sobre el mismo conjunto de test reservado, los resultados de los dos escenarios de coste desarrollados en las secciones anteriores: el escenario simétrico ($C_{FP} = C_{FN} = 1$, Sección 5) y el escenario asimétrico ($C_{FP} = 1$, $C_{FN} = 10$, Sección 6), en el que conceder crédito a un moroso -falso negativo- cuesta diez veces más que denegarlo a un buen pagador -falso positivo-. El estimador subyacente es, en ambos casos, exactamente el mismo XGBoost entrenado una única vez sobre las 84 000 observaciones de entrenamiento; lo único que cambia entre escenarios es el punto de corte θ que convierte la probabilidad de impago estimada en una decisión binaria (conceder/denegar). En los dos escenarios el umbral se optimiza por validación cruzada estratificada de 5 pliegues sobre las probabilidades *out-of-fold* (OOF) de **train**, nunca sobre **test**, que se reserva íntegro para el reporte final y se evalúa una única vez.

Metodología: umbral óptimo y coste esperado

Bajo una matriz de coste asimétrica en la que el acierto no cuesta nada, el umbral de decisión que minimiza el coste esperado de un clasificador binario bien calibrado tiene solución analítica cerrada:

$$\theta^* = \frac{C_{FP}}{C_{FP} + C_{FN}}$$

lo que da $\theta_1^* = \frac{1}{1+1} = 0.5000$ para el escenario simétrico y $\theta_{10}^* = \frac{1}{1+10} = 0.0909$ para el asimétrico. El umbral empírico se obtiene por búsqueda exhaustiva (*argmin*) del coste medio sobre las probabilidades OOF de **train**, y el coste esperado empírico sobre un conjunto de N observaciones se calcula directamente a partir de la matriz de confusión en el punto de corte elegido:

$$\overline{\text{Coste}} = \frac{C_{FP} \cdot FP + C_{FN} \cdot FN}{N}$$

Esta identidad es consistente con las cifras reportadas: en el escenario simétrico, $(1 \cdot 213 + 1 \cdot 1118)/21\,000 = 0.0634$; en el asimétrico, $(1 \cdot 2918 + 10 \cdot 396)/21\,000 = 0.3275$, ambos coincidentes con la columna **coste_test** de la Tabla 12.




Figura 18: Comparación directa de los dos escenarios de coste sobre el mismo modelo XGBoost: umbral óptimo, coste en test y tasa de denegación resultante en cada caso.

Resultados comparados en test

La Tabla 12 recoge, para cada escenario, la familia de modelo ganadora, el umbral óptimo empírico, el coste medio en **test**, el coste del baseline trivial de *conceder a todos* y la mejora relativa que logra el modelo umbralizado frente a ese baseline.

Cuadro 12: Comparativa de resultados en test entre el escenario simétrico y el asimétrico (fuente: `umbrales_coste.csv`).

Escenario	Umbral θ^*	Coste test	Coste conceder-todo	Denegación test	Mejora relativa
Simétrico ($C_{FN} = 1$)	0.4934	0.0634	0.0669	2.38 %	5.20 %
Asimétrico ($C_{FN} = 10$)	0.0906	0.3275	0.6686	18.70 %	51.01 %

El coste del baseline de *denegar a todos* es idéntico en ambos escenarios (0.9331), puesto que un solicitante denegado nunca genera falso negativo y por tanto ese coste no depende de C_{FN} ; en ambos casos queda muy por encima del coste del modelo umbralizado, que domina a los dos baselines triviales.

Reequilibrio de la matriz de confusión

Al mantenerse fijo el modelo y desplazarse únicamente el umbral, la matriz de confusión en test se reequilibra de forma predecible: al encarecer diez veces el falso negativo, el modelo se vuelve mucho más conservador a la hora de conceder crédito, lo que reduce los falsos negativos a costa de aumentar los falsos positivos. La Tabla 13 cuantifica ese trasvase.

Cuadro 13: Falsos positivos, falsos negativos y métricas de contexto en test, mismo modelo, dos umbrales.

Escenario	FP	FN	Precisión	Recall	AUC
Simétrico ($\theta = 0.4934$)	213	1118	0.5731	0.2037	0.8701
Asimétrico ($\theta = 0.0906$)	2918	396	0.2568	0.7179	0.8701

El AUC de test es idéntico (0.8701) en los dos escenarios: es prueba cuantitativa directa de que se trata del mismo modelo re-umbralizado y no de un reentrenamiento distinto, ya que el AUC es invariante al punto de corte y solo depende del ordenamiento de las probabilidades predichas.




Figura 19: Matriz de confusión en test bajo el umbral óptimo del escenario simétrico ($\theta = 0.4934$): predominan los falsos negativos (1118) sobre los falsos positivos (213), coherente con un recall bajo.




Figura 20: Contraste de matrices de confusión entre el umbral simétrico y el asimétrico: el trasvase de falsos negativos hacia falsos positivos al bajar el umbral de 0.4934 a 0.0906.

Tasa de denegación en test y en producción

La tasa de denegación en test sube de 2.38 % (escenario simétrico) a 18.70 % (escenario asimétrico). Como el objetivo de esta sección es comparar los dos escenarios de negocio y las etiquetas reales de producción permanecen ocultas -su evaluación final corresponde al profesor-, se emplea como proxy observable la tasa de denegación en producción, calculada directamente sobre la columna de decisión *predicha* (0 = concedido, 1 = denegado) que el modelo escribe en cada

fichero de entrega, sin requerir el target oculto. La Tabla 14 resume el resultado sobre las 45 000 solicitudes de cada fichero de producción.

Cuadro 14: Tasa de denegación en producción según el fichero de entrega (45 000 solicitudes cada uno).

Escenario	Fichero	Denegados	Tasa de denegación
Simétrico	<code>cs_produccion1.csv</code>	1060	2.36 %
Asimétrico	<code>cs_produccion2.csv</code>	8339	18.53 %

Puesto que el umbral asimétrico ($\theta = 0.0906$) es estrictamente inferior al simétrico ($\theta = 0.4934$), su conjunto de denegados es un superconjunto del anterior: aplicando el mismo scoring a las 45 000 solicitudes de producción, 7279 solicitantes (16.2 % del total) pasan de concedido a denegado al endurecer el criterio, y ninguno lo hace en sentido inverso.

Hallazgos

- El AUC de test es idéntico en los dos escenarios (0.8701): prueba cuantitativa de que es el mismo modelo re-umbralizado y no un reentrenamiento distinto. El umbral óptimo empírico cae de 0.4934 (simétrico) a 0.0906 (asimétrico), ambos muy próximos a sus umbrales analíticos teóricos ($\theta_1^* = 0.5$ y $\theta_{10}^* = 1/11 = 0.0909$): el scoring está bien calibrado en la zona de decisión relevante.
- El equilibrio FP/FN se invierte con fuerza al pasar del escenario simétrico al asimétrico: los falsos negativos caen de 1118 a 396 y los falsos positivos suben de 213 a 2918 (recall $0.2037 \rightarrow 0.7179$, precisión $0.5731 \rightarrow 0.2568$); el modelo se vuelve mucho más conservador a la hora de conceder crédito cuando el impago no detectado cuesta diez veces más.
- La mejora relativa frente al baseline de conceder-a-todos escala fuertemente con la asimetría: 5.20 % en el escenario simétrico frente a 51.01 % en el asimétrico, con la misma familia ganadora (`xgboost`) en ambos casos; el coste de denegar-a-todos es idéntico en los dos escenarios (0.9331) porque no depende de C_{FN} .
- La tasa de denegación en test sube de 2.38 % a 18.70 %; en producción el patrón se repite de forma casi idéntica (2.36 % frente a 18.53 % sobre 45 000 solicitudes), calculada sobre la decisión predicha por el modelo, no sobre una etiqueta real, lo que permite reportarla sin conocer el target oculto.
- Del escenario simétrico al asimétrico, 7279 de los 45 000 solicitantes de producción (16.2 %) pasan de concedido a denegado, y ninguno en sentido inverso: al ser el umbral asimétrico estrictamente más bajo, sus denegados incluyen a todos los del escenario simétrico más los nuevos casos límite que quedan por debajo del nuevo corte.

6. Auditoría: modelo subrogado con reglas

6.1. Metodología: fidelidad frente a exactitud

Para auditar el comportamiento del modelo de caja negra (XGBoost) se entrena, para cada escenario de coste, un árbol de decisión (`DecisionTreeClassifier`) que **no** predice el impago real: imita la *decisión* que XGBoost toma (conceder o denegar) una vez aplicado el umbral de coste correspondiente. Recordemos que dicha decisión surge de comparar la probabilidad de impago estimada con el umbral óptimo de cada escenario, obtenido por búsqueda exhaustiva sobre las probabilidades OOF de train y próximo al óptimo analítico

$$\theta^* = \frac{C_{FP}}{C_{FP} + C_{FN}},$$

con $\theta_{\text{coste1}}^* = 0.4934$ (analítico 0.5) y $\theta_{\text{coste10}}^* = 0.0906$ (analítico $1/11 = 0.0909$).

Por construcción, el árbol subrogado se evalúa por **fidelidad** respecto a la caja negra, no por exactitud frente al impago verdadero. Sea n el número de observaciones de test, $\hat{y}_i^{\text{caja}} \in \{0, 1\}$ la decisión de XGBoost + umbral (1 = denegar) y $\hat{y}_i^{\text{sub}} \in \{0, 1\}$ la decisión del árbol subrogado para la observación i . Se definen:

$$F_{\text{global}} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[\hat{y}_i^{\text{sub}} = \hat{y}_i^{\text{caja}}] \quad (1)$$

$$F_{\text{denegar}} = \frac{\sum_{i=1}^n \mathbf{1}[\hat{y}_i^{\text{sub}} = 1 \wedge \hat{y}_i^{\text{caja}} = 1]}{\sum_{i=1}^n \mathbf{1}[\hat{y}_i^{\text{caja}} = 1]} \quad (2)$$

F_{global} es la proporción de observaciones en las que el subrogado reproduce la decisión de la caja negra; F_{denegar} es el recall del subrogado sobre la clase *denegar* tomando como referencia la propia caja negra (no el impago real). El $F1_{\text{denegar}}$ se calcula como la media armónica de precisión y F_{denegar} , ambas respecto a la etiqueta de la caja negra.

Esta distinción es crítica bajo el fuerte desbalanceo de decisiones del escenario simétrico (solo el 2.38% de test es denegado): un árbol degenerado que concediera siempre alcanzaría $F_{\text{global}} = 0.9762$ sin haber aprendido ningún patrón de denegación ($F_{\text{denegar}} = 0$). Por ello se barre la profundidad del árbol (de 2 a 10) y el peso asignado a la clase *denegar*, observando siempre la fidelidad de la clase rara y no solo la global.




Figura 21: Fidelidad global, fidelidad de la clase denegar y $F1$ -denegar en función de la profundidad del árbol y del peso de clase, escenario *coste1*. La fidelidad global satura casi plana cerca de 0.98 desde poca profundidad, mientras que la fidelidad de la clase denegar sigue mejorando con la profundidad y depende fuertemente del peso de clase: ahí reside el verdadero límite de aprendizaje del subrogado.

A partir de este barrido se fijan, para cada escenario, dos árboles con propósitos distintos:

- **Árbol operativo** (profundidad 5, 23 hojas): maximiza la fidelidad y se emplea para la auditoría técnica del modelo.
- **Árbol de bolsillo** (profundidad 3, 8 hojas): legible de un vistazo, pensado para comunicar la lógica de decisión a un cliente o a un revisor no técnico.

Los umbrales de las reglas resultantes se traducen a euros, años y ratios reales (no a la escala estandarizada interna del pipeline) invirtiendo las transformaciones de `PreprocesadorCredito` (winsorizado, $\log(1 + x)$ y escalado).

6.2. Los dos árboles de bolsillo: dos personalidades de riesgo




Figura 22: Árbol de bolsillo del escenario coste1 (umbral 0.4934, deniega al 2.38 % de los solicitantes). La variable de la raíz es el número de impagos de 90 o más días: un criterio conservador basado en mora ya consumada.




Figura 23: Árbol de bolsillo del escenario coste10 (umbral 0.0906, deniega al 18.70 % de los solicitantes). La variable de la raíz es la utilización de crédito revolving: un criterio preventivo basado en una señal de estrés financiero temprano.

Ambos árboles provienen del mismo XGBoost; la única diferencia es el umbral de coste aplicado aguas abajo. Aun así, la variable que ocupa la raíz del árbol de bolsillo se invierte por completo entre escenarios, lo que anticipa el resultado de importancia de variables de la Sección 6.4.




Figura 24: Árbol operativo completo (23 hojas) del escenario coste10. Con mayor profundidad se despliega la jerarquía completa de la variable dominante (utilización de crédito revolving) combinada con variables de mora y edad; de estas ramas se extraen, una por una, las reglas de denegación listadas en la Sección 6.5.

6.3. Fidelidad de los cuatro subrogados fijados

La Tabla 15 recoge la fidelidad de los cuatro árboles fijados (operativo y bolsillo, en cada escenario), junto con la tasa de denegación real de la caja negra y la que reproduce cada subrogado, como chequeo de sanidad independiente de las métricas de fidelidad.

Cuadro 15: Fidelidad de los subrogados frente a la caja negra (XGBoost + umbral de coste) en test.

Subrogado	Hojas	Denegación caja negra	Denegación subrogado	Fidelidad global	Fidelidad denegar	$F1$
Coste1 operativo (d=5)	23	0.0238	0.0259	0.9879	0.7896	0.8867
Coste1 bolsillo (d=3)	8	0.0238	0.0353	0.9809	0.8397	0.9053
Coste10 operativo (d=5)	23	0.1870	0.1876	0.9415	0.8454	0.8934
Coste10 bolsillo (d=3)	8	0.1870	0.1196	0.9173	0.5988	0.7281

En los cuatro casos la tasa de denegación reproducida por el subrogado se aproxima a la de la caja negra (0.0259 vs. 0.0238 en coste1 operativo; 0.1876 vs. 0.1870 en coste10 operativo), lo que confirma que el árbol no solo clasifica bien en promedio, sino que replica el volumen real de decisiones adversas.

6.4. Importancia de variables en cada subrogado

La Tabla 16 muestra la importancia de variables (basada en la reducción de impureza) del árbol operativo de cada escenario.

Cuadro 16: Importancia de variables del árbol subrogado operativo, por escenario de coste.

Variable	Importancia coste1	Importancia coste10
N. impagos 90+ días	0.7155	0.1875
N. moras 60–89 días	0.1219	0.0685
N. moras 30–59 días	0.0734	0.2105
Utilización de crédito revolving	0.0397	0.4914
N. líneas de crédito abiertas	0.0208	0.0004
Edad	0.0165	0.0392
Ratio de deuda	0.0089	0.0000
Ingreso mensual	0.0032	0.0024

La variable dominante se invierte entre escenarios: en `coste1` domina el número de impagos de 90 o más días (importancia 0.7155), coherente con un modelo conservador que solo deniega ante mora ya consumada; en `coste10` domina la utilización de crédito revolving (importancia 0.4914), coherente con un modelo preventivo que deniega ante la primera señal de estrés financiero, mientras que los impagos de 90+ días caen al tercer puesto (0.1875).

6.5. Reglas de denegación destiladas

De las ramas del árbol operativo de 23 hojas que terminan en *denegar* se extraen reglas legibles, con umbrales ya expresados en euros, años y ratios reales:

- **Coste1:** 8 reglas cubren 543 de las denegaciones de test. La regla principal (soporte 118, pureza 100 %) deniega si el número de impagos de 90 o más días es ≥ 2 , el número de moras de 60–89 días es ≥ 2 y la utilización de crédito revolving supera el 91 %.
- **Coste10:** 18 reglas cubren 3940 de las denegaciones de test. La regla principal (soporte 975, pureza 100 %) deniega si la utilización de crédito revolving supera el 77 %, el número de moras de 30–59 días es ≥ 2 , la edad es ≤ 63.5 años y el ingreso mensual es $\leq 12\,506.50$ EUR.
- **Interacción edad $\times$ mora (coste1):** dentro del subconjunto con impagos de 90+ días ≥ 2 y moras de 60–89 días ≤ 1 , con moras de 30–59 días ≥ 2 , el corte de edad separa claramente el riesgo: edad > 43.5 años da pureza 75.0 % (soporte 58) frente a edad ≤ 43.5 años con pureza 98.0 % (soporte 53). Esta interacción se corrobora de forma independiente con el PDP bidimensional presentado en la sección de otras técnicas de explicabilidad del notebook.

6.6. Hallazgos

- La fidelidad global engaña bajo desbalanceo: en `coste1`, el árbol degenerado que *concede siempre* alcanza $F_{\text{global}} = 0.9762$ con $F_{\text{denegar}} = 0$ (no aprendió ningún patrón de denegación); el árbol operativo real eleva el global a 0.9879 **y además** la fidelidad de la clase denegar a 0.7896 ($F1_{\text{denegar}} = 0.7562$). Debe examinarse siempre la fidelidad de la clase rara, nunca la global de forma aislada.
- El peso óptimo de la clase *denegar* depende del escenario: 3 en `coste1` (clase rara, 2.38 % de denegaciones) frente a sin reponderar en `coste10` (clase frecuente, 18.70 %); en ambos casos el árbol operativo reproduce casi con exactitud la tasa de denegación real de la caja negra (2.59 % vs. 2.38 % en `coste1`; 18.76 % vs. 18.70 % en `coste10`), un chequeo de sanidad independiente del $F1$.
- Se identifican dos personalidades de riesgo: la variable más importante se invierte entre escenarios. En `coste1` domina el número de impagos de 90+ días (importancia 0.7155), un modelo conservador que solo deniega ante mora ya consumada; en `coste10` domina la utilización de crédito revolving (importancia 0.4914), un modelo preventivo que deniega ante la primera señal de estrés, con los impagos de 90+ días relegados al tercer puesto (0.1875). Mismo XGBoost, misma pareja de árboles, lógica de decisión opuesta según dónde se fija el umbral de coste.
- El árbol de bolsillo (8 hojas) tiene un $F1$ más bajo en `coste1` (0.6758) que en `coste10` (0.7304), pero en cobertura el orden se invierte: cubre el 83.97 % de las denegaciones reales en `coste1` frente a solo el 59.88 % en `coste10`. El bolsillo asimétrico es muy preciso pero con poca profundidad: 8 hojas son un techo estructural que en `coste10` deja fuera a 4 de cada 10 denegaciones.

- La brecha entre el árbol operativo y el de bolsillo en $F1$ es mayor en `coste10` (0.8439 frente a 0.7304, diferencia -0.1135) que en `coste1` (0.7562 frente a 0.6758, diferencia -0.0804): con más denegaciones que cubrir (18.70 % frente a 2.38 %), 8 reglas resultan insuficientes antes.

Nota de reproducibilidad. Al recargar el XGBoost serializado (`.joblib`) con una versión de la librería distinta a la usada en el entrenamiento, el parámetro interno `base_score` se reconstruía de forma incorrecta e inflaba las probabilidades por un factor de aproximadamente 5 (denegaría al 25 % / 85 % de los solicitantes en vez del 2.4 % / 18.7 % real). El problema se detectó y corrigió fijando la versión exacta de XGBoost en las dependencias antes de ejecutar esta auditoría, garantizando que todas las cifras anteriores correspondan al modelo realmente entrenado.

7. Auditoría: análisis de contrafactuales

Objetivo y metodología. Un contrafactual responde a la pregunta *¿qué habría tenido que cambiar el solicitante para que el modelo concediera el crédito?*. Formalmente, dado el clasificador $f : \mathcal{X} \rightarrow [0, 1]$ que estima $p(\text{impago} \mid x)$ y la regla de decisión de negocio

$$\hat{y}(x) = \mathbf{1}[f(x) \geq \theta],$$

con θ el umbral operativo de cada escenario ($\theta = 0,4934$ en `coste1`, $\theta = 0,0906$ en `coste10`; véanse las secciones 5 y 6), un contrafactual accionable para una instancia denegada x (con $f(x) \geq \theta$) es una instancia x' que invierte la decisión, $f(x') < \theta$, modificando únicamente un subconjunto acotado de variables accionables.

La búsqueda se realiza con la librería DiCE (*Diverse Counterfactual Explanations*), cuya frontera interna de decisión está fijada de fábrica en 0,5. Como los umbrales de negocio reales (0,4934 y 0,0906) no coinciden con esa frontera, se interpone un modelo adaptador que traslada la frontera interna de DiCE al umbral de negocio real de cada escenario. Así, la optimización de DiCE persigue siempre la decisión de negocio realmente aplicada por el banco en cada escenario, y no una frontera genérica al 50 %.

La búsqueda se restringe a cuatro variables accionables –utilización de crédito revolving, ratio de deuda (`DebtRatio`), ingresos mensuales y número de líneas de crédito abiertas–, con límites de cambio realistas por solicitante:

$$x'_{\text{ingresos}} \leq 1,25 x_{\text{ingresos}}, \quad x'_{\text{revolving}} \geq 0,70 x_{\text{revolving}}, \quad x'_{\text{DebtRatio}} \geq 0,70 x_{\text{DebtRatio}}, \quad x'_{\text{lineas}} \geq x_{\text{lineas}} - 2.$$

El resto de variables (edad, historial de impagos, personas dependientes, etc.) permanece fijo. Cada candidato generado por DiCE se somete a seis comprobaciones antes de traducirse a una explicación para el cliente: (1) rango observado en los datos, (2) ausencia de valores negativos, (3) las variables inmutables no cambian, (4) el cambio va en la dirección favorable al solicitante, (5) las variables de conteo entero conservan valores enteros y (6) la decisión realmente se invierte bajo el umbral de negocio.

Selección de casos. Se seleccionan 8 solicitudes denegadas: 2 por clase real ($0/1$) $\times$ 2 escenarios de coste (`coste1`, `coste10`), etiquetadas como `borde_umbral` (la más cercana al umbral) o `denegacion_fuerte` ($p(\text{impago})$ más alta). La clase real del solicitante determina el uso legítimo del contrafactual: si en realidad no habría impagado (falso positivo del modelo, `clase_real=0`), el contrafactual es una explicación literal comunicable al cliente (`uso_explicacion = explicacion_cliente_fal.`); si el modelo acertó al denegar (`clase_real=1`), el contrafactual solo tiene valor de auditoría interna del comportamiento del modelo y no debe presentarse como promesa de aprobación (`uso_explicacion = auditoria_interna_denegacion_correcta`).

7.1. Resultado principal

De las 8 solicitudes analizadas, DiCE genera un contrafactual accionable en los 4 casos **borde_umbral** (4/4) y en ninguno de los 4 casos **denegacion_fuerte** (0/4): la distancia al umbral condiciona por completo la existencia de una explicación accionable, no la clase real del solicitante. De los 4 generados, 3 resultan plausibles tras las seis comprobaciones: 2/2 en **coste1** y 1/2 en **coste10**.

Cuadro 17: Resultado del análisis de contrafactuales por caso (8 solicitudes denegadas).

id_test	escenario	clase_real	tipo_caso	estado_cf	plausible
52346	coste1	0	borde_umbral	generado	sí
28495	coste1	0	denegacion_fuerte	sin_cf_accionable	no
10358	coste1	1	borde_umbral	generado	sí
79585	coste1	1	denegacion_fuerte	sin_cf_accionable	no
19744	coste10	0	borde_umbral	generado	sí
28495	coste10	0	denegacion_fuerte	sin_cf_accionable	no
14183	coste10	1	borde_umbral	generado	no
79585	coste10	1	denegacion_fuerte	sin_cf_accionable	no

Cuadro 18: Resumen por escenario: probabilidad de impago media de los 4 casos seleccionados, contrafactuales generados y plausibles.

Escenario	$p(\text{impago})$ media	Generados	Plausibles
coste1	0,6843	2	2
coste10	0,4829	2	1

La probabilidad de impago media resume qué tan lejos del umbral están, en promedio, los 4 casos de cada escenario (0,6843 en **coste1** frente a 0,4829 en **coste10**); en términos absolutos, ambos grupos mezclan casos **borde_umbral** con casos **denegacion_fuerte**, muy por encima del corte.




Figura 25: Probabilidad de impago original frente a probabilidad tras el contrafactual, para los 3 casos con contrafactual generado y plausible (2 puntos en **coste1**, 1 en **coste10**). No incluye los 4 casos sin contrafactual ni el caso generado pero descartado por implausible ($\text{id_test}=14183$).

7.2. Casos ilustrativos

Caso 52346 (coste1**, **borde_umbral**, **clase_real=0**, falso positivo, contrafactual plausible).** La solicitud fue denegada con un riesgo estimado del 49,4 %, por encima del umbral del escenario (49,3 %). Reduciendo la utilización de crédito revolving de 110,3 % a 109,3 % y aumentando los ingresos mensuales de 4.720 a 5.863 EUR, el riesgo estimado desciende al 45,9 % y la

decisión del modelo se revierte a conceder. Esta es la explicación de referencia para responder a la pregunta *qué decirle a un cliente denegado* cuando existe contrafactual plausible: se comunican los cambios concretos, aclarando siempre que describe el comportamiento del modelo y no constituye una garantía de aprobación futura.

Caso 28495 (denegacion_fuerte, clase_real=0, sin contrafactual en ningún escenario). Con $p(\text{impago}) = 0,833$, muy por encima de ambos umbrales, DiCE no encuentra ninguna combinación razonable de cambios en las 4 variables accionables, dentro de los límites establecidos, que revierta la decisión. La respuesta honesta al cliente reconoce que el método no halló una alternativa válida bajo esas restricciones, sin afirmar que la aprobación sea imposible en el futuro.

Caso 10358 (coste1, borde_umbral, clase_real=1, correctamente denegado). Riesgo estimado 49,4 % frente al umbral 49,3 %; subiendo únicamente los ingresos de 2.697 a 3.120 EUR el riesgo baja al 48,3 % y la decisión se revierte. Al ser `clase_real=1`, este contrafactual sirve exclusivamente de auditoría interna del comportamiento del modelo, no como recomendación al cliente.

Caso 19744 (coste10, borde_umbral, clase_real=0). Riesgo 9,1 % frente al umbral 9,1 % ($\theta = 0,0906$); bajando la utilización de revolving de 100,0 % a 70,7 % el riesgo cae al 6,8 %, ejemplo del escenario asimétrico, más conservador.

Caso 14183 (coste10, borde_umbral, clase_real=1, contrafactual generado pero descartado). DiCE encuentra técnicamente una alternativa (DebtRatio de 1,283 a 0,908 y líneas de crédito abiertas de 12 a 8, riesgo de 9,1 % a 6,5 %), pero se descarta en la verificación de plausibilidad: el valor interno del contrafactual para el número de líneas de crédito es fraccionario, no un entero válido (falla la comprobación de conteos enteros). Este caso ilustra un matiz operativo relevante: el texto de cliente ya redondeado (12 $\rightarrow$ 8) se genera igualmente porque la lógica condiciona el texto a la existencia de un contrafactual generado, no a su plausibilidad; por ello no debería usarse como explicación real pese a tener una redacción aparentemente correcta.

Caso 79585 (denegacion_fuerte, clase_real=1). Con $p(\text{impago}) = 0,917$, tampoco se encuentra contrafactual en ninguno de los dos escenarios.

7.3. Hallazgos

- Solo existe contrafactual accionable en los casos `borde_umbral` (4/4 generados); en `denegacion_fuerte`, 0/4. La distancia al umbral de decisión condiciona por completo si hay una explicación accionable, no la clase real del solicitante.
- De los 4 contrafactuales generados, 3 son plausibles: 2/2 en `coste1` y 1/2 en `coste10`. El único descartado (`id_test=14183`, `coste10`) falla por un conteo no entero en `NumberOfOpenCreditLinesAndLoan`.
- Los límites de accionabilidad usados por DiCE son concretos y fijos por diseño: ingresos hasta +25 %, revolving y `DebtRatio` hasta -30 %, cierre de hasta dos líneas de crédito; el resto de variables (edad, impagos previos, personas dependientes) permanece fijo.
- La probabilidad de impago media de los 8 casos seleccionados es 0,6843 en `coste1` y 0,4829 en `coste10`: en ambos escenarios se mezclan casos muy cerca del umbral (`borde_umbral`) con otros muy por encima (`denegacion_fuerte`), como los casos `id_test=28495` y `id_test=79585`, repetidos en ambos escenarios con $p(\text{impago}) = 0,833$ y 0,917 respectivamente.
- La distinción `uso_explicacion` (`explicacion_cliente_falso_positivo` frente a `auditoria_interna_d`) marca si el contrafactual se puede comunicar como explicación al cliente o si solo sirve para auditar internamente el modelo: con `clase_real=1` (correctamente denegado) nunca debería presentarse como promesa de aprobación, aunque el contrafactual exista y sea plausible.
- El caso descartado por implausibilidad (`id_test=14183`) evidencia un riesgo metodológico general de los sistemas de contrafactuales: la generación de un texto explicativo no garantiza por sí sola su validez; la comprobación de plausibilidad debe aplicarse siempre antes de comunicar cualquier resultado.

8. Auditoría: análisis SHAP global y local (cotejo con LIME)

Para auditar las decisiones del XGBoost ganador se aplica **TreeExplainer**, el algoritmo exacto de la librería SHAP (*SHapley Additive exPlanations*) diseñado específicamente para modelos basados en árboles, sobre las 21 000 observaciones del conjunto de test. El cálculo se repite por separado para el escenario simétrico (`modelo_coste1`) y el asimétrico (`modelo_coste10`), aunque ambos comparten exactamente el mismo estimador XGBoost y solo difieren en el umbral que traduce la puntuación de riesgo en decisión de conceder o denegar crédito.

8.1. Metodología: valores de Shapley y aditividad

El valor de Shapley de la variable i para una instancia x , con N el conjunto de las M variables del modelo, se define como el promedio ponderado de su contribución marginal sobre todos los subconjuntos S que no la contienen:

$$\phi_i(x) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (M - |S| - 1)!}{M!} [f_x(S \cup \{i\}) - f_x(S)]$$

TreeExplainer aprovecha la estructura del ensamblado de árboles para calcular estos valores de forma exacta (no aproximada por muestreo), garantizando la propiedad de aditividad local que permite descomponer cualquier predicción individual en la suma de las contribuciones de cada variable:

$$f(x) = \phi_0 + \sum_{i=1}^M \phi_i(x)$$

donde ϕ_0 es el valor esperado del modelo sobre el conjunto de referencia (*background*) y $f(x)$ es la salida cruda del XGBoost en escala *log-odds* (margen), no la probabilidad directa: $P(\text{impago} \mid x) = \sigma(f(x)) = 1/(1 + e^{-f(x)})$. Esta distinción es relevante para no confundir la magnitud de las barras de un *waterfall* con probabilidades al leerlas junto a los umbrales de decisión (0,4934 en el escenario simétrico, 0,0906 en el asimétrico).

8.2. Importancia global

La Figura 26 resume, para el escenario simétrico, la importancia media absoluta de cada variable (`mean_abs_shap` = $\frac{1}{n} \sum_{j=1}^n |\phi_i(x_j)|$ sobre las n observaciones de test) junto con el sentido del efecto (color: rojo = valor alto de la variable, azul = valor bajo).




Figura 26: Resumen SHAP global, escenario simétrico (coste1): importancia media absoluta por variable y sentido del efecto.

`RevolvingUtilizationOfUnsecuredLines` (utilización de crédito revolving) domina la importancia global con $\text{mean_abs_shap} = 0,7873$, más del doble ($2,26\times$) que la siguiente variable, `NumberOfTime30-59DaysPastDueNotWorse` ($0,3486$); le siguen `NumberOfTimes90DaysLate` ($0,3278$) y `age` ($0,2273$). La Tabla 19 recoge el detalle de las seis variables más importantes.

Cuadro 19: Importancia global SHAP (mean_abs_shap) y ranking, escenario coste1 – top 6 variables.

Variable	mean_abs_shap	Ranking
<code>RevolvingUtilizationOfUnsecuredLines</code>	0,7873	1
<code>NumberOfTime30-59DaysPastDueNotWorse</code>	0,3486	2
<code>NumberOfTimes90DaysLate</code>	0,3278	3
<code>age</code>	0,2273	4
<code>NumberOfTime60-89DaysPastDueNotWorse</code>	0,1735	5
<code>NumberOfOpenCreditLinesAndLoans</code>	0,1592	6




Figura 27: Resumen SHAP global, escenario asimétrico (coste10): mismo ranking y mismos valores que en coste1.

Comparando la Figura 27 con la Figura 26: son idénticas. Los escenarios `coste1` y `coste10` comparten exactamente el mismo ranking y los mismos valores SHAP (diferencia máxima = 0), porque el estimador subyacente es el mismo XGBoost; únicamente cambia el umbral de decisión aguas abajo (0,4934 en `coste1` frente a 0,0906 en `coste10`), elegido según el coste de cada escenario.

8.3. Explicaciones locales

Además del resumen global se construyen explicaciones locales tipo *waterfall* para casos individuales denegados, incluido un caso de borde (justo por encima del umbral de decisión). En un *waterfall*, las barras rojas empujan la puntuación hacia el impago y las azules hacia el pago.




Figura 28: Explicación local SHAP (*waterfall*), caso de borde `id_test=52346`, escenario `coste1`.

El caso de borde `id_test=52346` (escenario `coste1`, clase real 0) tiene $P(\text{impago}) = 0,493506$ frente al umbral $\theta = 0,493394$, un margen de solo $+0,000112$: una denegación muy ajustada, prácticamente en el límite exacto de la decisión.




Figura 29: Explicación local SHAP (*waterfall*), caso `id_test=28495` (denegación fuerte), escenario `coste1`.

El caso `id_test=28495` está presente en ambos escenarios de coste (junto con el `id_test=79585`); su explicación SHAP es idéntica en `coste1` y `coste10` (diferencia máxima = 0,0), evidencia adicional -a nivel de instancia individual- de que el modelo base no cambia entre escenarios y de que toda la diferencia de comportamiento reside en el umbral aplicado.

8.4. Cotejo de fiabilidad: SHAP frente a LIME

De forma independiente a las explicaciones anteriores se coteja la fiabilidad de SHAP frente a LIME sobre 6 clientes denegados (3 por escenario, seleccionados aparte de los casos usados en las figuras locales y en la auditoría de contrafactuales): se reejecuta LIME 6 veces por caso

para medir cuánto varía el peso que asigna a cada variable, se contrasta con la varianza nula de SHAP -que al ser exacto da siempre el mismo resultado- y se mide el acuerdo entre los rankings de variables de ambos métodos con el coeficiente de correlación de Spearman en valor absoluto:

$$\rho = 1 - \frac{6 \sum_{k=1}^n d_k^2}{n(n^2 - 1)}$$

donde d_k es la diferencia entre el rango que SHAP y el rango que LIME asignan a la variable k , y n es el número de variables comparadas.




Figura 30: Dispersión de los pesos de LIME entre reejecuciones (barras de error) frente a la ausencia de varianza de SHAP.

Cuadro 20: Cotejo cuantitativo SHAP vs LIME sobre 6 casos denegados (6 reejecuciones de LIME por caso).

Escenario	idx_caso	lime_std_media	shap_std	Spearman $ \rho $	top1 coincide
coste1	3665	0,0057	0,0	0,5175	Sí
coste1	11076	0,0055	0,0	0,6014	Sí
coste1	19825	0,0056	0,0	0,3147	No
coste10	976	0,0057	0,0	0,5524	No
coste10	14834	0,0055	0,0	0,5245	No
coste10	17133	0,0058	0,0	0,4266	No

SHAP es exacto y determinista ($\text{shap_std} = 0,0$ en los 6 casos evaluados) mientras LIME fluctúa entre reejecuciones ($\text{lime_std_media} \approx 0,0056$, hasta 0,0357 en el caso `coste10 idx_caso=976`); el acuerdo de ranking entre ambos métodos es solo moderado (Spearman medio $\approx 0,49$, rango 0,31–0,60) y el top-1 coincide en apenas 2 de los 6 casos. Además, LIME señala `es_centinela_pastdue` (variable centinela de historial de mora) como la variable más inestable en los 6 casos, justo la que SHAP considera casi irrelevante ($\text{mean_abs_shap} = 0,0146$, ranking 11 de 12): SHAP se establece como la referencia más fiable para auditar decisiones individuales.

Hallazgos

- `RevolvingUtilizationOfUnsecuredLines` domina la importancia global con `mean_abs_shap = 0,7873`, más del doble ($2,26\times$) que la siguiente variable, `NumberOfTime30-59DaysPastDueNotWorse` (`0,3486`); le siguen `NumberOfTimes90DaysLate` (`0,3278`) y `age` (`0,2273`).
- Los escenarios `coste1` y `coste10` comparten exactamente el mismo ranking y los mismos valores SHAP (diferencia = 0) porque es el mismo XGBoost; solo cambia el umbral de decisión (`0,4934` frente a `0,0906`), confirmado también a nivel de instancia: los `id_test` `28495` y `79585` aparecen en ambos escenarios con SHAP idéntico (diferencia máxima = 0,0).
- SHAP es exacto y determinista (`shap_std = 0,0` en los 6 casos evaluados) mientras LIME fluctúa entre reejecuciones (`lime_std_media` $\approx 0,0056$, hasta `0,0357` en `coste10 idx_caso=976`); el acuerdo de ranking entre ambos métodos es solo moderado (Spearman medio $\approx 0,49$, rango `0,31-0,60`) y el top-1 coincide en apenas 2 de 6 casos.
- LIME señala `es_centinela_pastdue` como la variable más inestable en los 6 casos, justo la que SHAP considera casi irrelevante (`mean_abs_shap = 0,0146`, ranking 11 de 12): SHAP es la referencia más fiable para auditar decisiones individuales.
- El caso de borde `id_test=52346` se decide por un margen mínimo ($+0,000112$ sobre el umbral): una denegación tan ajustada refuerza por qué interesa auditar también con contrafactuales, además de con SHAP.

9. Otras técnicas de explicabilidad consideradas

El enunciado invita a incorporar “otras técnicas que los estudiantes consideren oportunas”. Se aplican cuatro técnicas de explicabilidad agnósticas al modelo (operan sobre `predict_proba`, sin asumir estructura de árbol), ejecutadas de forma independiente del árbol subrogado y del análisis SHAP descritos en apartados anteriores, sobre los dos modelos de coste ya entrenados: el escenario simétrico ($C_{FP} = C_{FN} = 1$) y el asimétrico ($C_{FP} = 1$, $C_{FN} = 10$), que comparten el mismo estimador XGBoost y solo difieren en el umbral θ que convierte la puntuación de riesgo en decisión. Las cuatro técnicas son: (1) importancia por permutación contrastada a tres bandas, (2) dependencia parcial (PDP) y curvas ICE, incluida una superficie PDP en dos dimensiones, (3) reejecución repetida de LIME para cuantificar su inestabilidad, y (4) una auditoría descriptiva de subgrupos por tramo de edad.

Limitaciones declaradas de entrada: la importancia por permutación y el PDP/ICE se calculan sobre submuestras (3000 y 2000 filas respectivamente, no sobre las 21 000 de test), el PDP en dos dimensiones usa una rejilla de 15×15 puntos, y LIME solo se reejecuta sobre 3 casos denegados por escenario (6 en total). Son suficientes para ilustrar el fenómeno, no para generalizar con la misma solidez que el análisis SHAP completo.

9.1. Importancia por permutación a tres bandas

La importancia por permutación mide cuánto empeora el coste esperado de negocio cuando se destruye la relación entre una variable x_j y el objetivo, barajando aleatoriamente sus valores en la muestra y manteniendo fijas todas las demás variables y el umbral de decisión θ vigente en el escenario:

$$PI_j(\theta) = C(\hat{y}^{(\pi_j)}(\theta)) - C(\hat{y}(\theta)), \quad C(\theta) = C_{FP} \cdot FP(\theta) + C_{FN} \cdot FN(\theta),$$

donde $\hat{y}^{(\pi_j)}(\theta)$ son las decisiones obtenidas tras permutar x_j y $C(\theta)$ es la misma función de coste esperado empleada en la selección de umbral de los apartados de modelado. El cálculo se repite 10 veces sobre una submuestra de 3000 filas de test y se promedia. Este valor se contrasta con dos referencias adicionales: la importancia nativa de XGBoost (ganancia de impureza acumulada

por las variables en todos los *splits* del árbol, independiente del umbral) y la importancia del árbol subrogado que imita las decisiones del modelo bajo cada umbral.




Figura 31: Importancia a tres bandas (permutación, XGBoost nativo, subrogado) por variable, para el escenario simétrico (coste1, panel superior) y el asimétrico (coste10, panel inferior).

Cuadro 21: Escenario simétrico (coste1): 5 variables principales según XGBoost nativo.

Variable	Permutación (media)	XGBoost nativo	Subrogado (d5)
N. impagos 90+ días	0.0020	0.3301	0.7155
Utilización de crédito revolving	0.0014	0.1922	0.0397
N. moras 60-89 días	0.0012	0.1493	0.1219
N. moras 30-59 días	0.0022	0.1298	0.0734
Centinela mora (flag)	0.0002	0.0715	N/D

Cuadro 22: Escenario asimétrico (coste10): 5 variables principales según importancia por permutación.

Variable	Permutación (media)	XGBoost nativo	Subrogado (d5)
Utilización de crédito revolving	0.0782	0.1922	0.4914
N. impagos 90+ días	0.0604	0.3301	0.1875
N. moras 60-89 días	0.0483	0.1493	0.0685
N. moras 30-59 días	0.0376	0.1298	0.2105
Ratio de deuda	0.0183	0.0184	0.0000

- En coste1 (escenario casi trivial) la importancia por permutación escalada al coste de negocio es prácticamente plana (0.0000–0.0022): romper cualquier variable apenas mueve un coste esperado que ya es mínimo, aunque la jerarquía interna de variables se mantenga intacta. En cambio, XGBoost nativo y el subrogado coinciden con claridad en que *N. impagos 90+ días* domina (0.3301 nativo, 0.7155 subrogado).
- En coste10, permutación y subrogado sí coinciden en que *Utilización de crédito revolving* es la variable que más pesa en las decisiones actuales (0.0782 permutación, 0.4914 subrogado), pero XGBoost nativo sigue puntuando más alto *N. impagos 90+ días* (0.3301, idéntico a coste1): su importancia mide ganancia de impureza sobre todos los *splits* del árbol, no está condicionada al umbral vigente – una cosa es discriminar mejor en general, otra pesar más en la decisión concreta que se está tomando.
- Ninguna de las tres métricas cuenta la historia completa por sí sola: la importancia nativa describe el modelo en abstracto, la del subrogado describe cómo se explican sus decisiones,

y la permutación describe cuánto importa cada variable para el coste de negocio bajo el umbral realmente en uso.

9.2. Dependencia parcial (PDP) y curvas ICE

El gráfico de dependencia parcial (*Partial Dependence Plot*, PDP) estima el efecto marginal de un subconjunto de variables x_S sobre la predicción del modelo, promediando sobre la distribución empírica del resto de variables x_C :

$$\widehat{\text{PDP}}(x_S) = \frac{1}{n} \sum_{i=1}^n \hat{f}(x_S, x_C^{(i)}),$$

calculado aquí sobre una submuestra de 2000 filas de test, con $\hat{f}$ la probabilidad de impago (o de denegación, una vez aplicado el umbral) predicha por el XGBoost. Las curvas ICE (*Individual Conditional Expectation*) son las trayectorias individuales $\hat{f}(x_S, x_C^{(i)})$ sin promediar, una por observación i : permiten detectar heterogeneidad que el PDP, al promediar, podría ocultar. Además del PDP univariante sobre *Utilización de crédito revolving*, se calcula un PDP en dos dimensiones para la interacción Edad $\times$ N. de moras de 30-59 días, con ambos ejes ya traducidos a años y unidades reales mediante el pipeline de preprocesado, sobre una rejilla de 15×15 puntos.




Figura 32: PDP en dos dimensiones: interacción Edad $\times$ N. de moras de 30-59 días sobre $P(\text{denegar})$.




Figura 33: Curvas ICE individuales y PDP (línea gruesa) de *Utilización de crédito revolving*.

- El rango de $P(\text{denegar})$ explicado solo por la edad es 0.0448 sin historial de mora frente a 0.0888 con 8 moras (el máximo de la rejilla) – prácticamente el doble –, lo que confirma con un método agnóstico independiente del árbol subrogado la interacción Edad $\times$ mora que ya aparecía dentro de las reglas del subrogado.
- Matiz relevante: la superficie de probabilidad del PDP es idéntica entre los dos escenarios de coste, porque es el mismo estimador XGBoost; lo único que cambia entre *coste1* y *coste10* es dónde corta cada umbral esa misma geometría. Esto refina, no contradice, la idea de “dos personalidades de riesgo”: la personalidad distinta está en el umbral, no en el modelo.
- La mayoría de las curvas ICE de *Utilización de crédito revolving* sube de forma monótona, pero el punto en el que empiezan a subir difiere bastante entre clientes: la variable que domina la importancia en las decisiones del escenario asimétrico no actúa igual para todos los perfiles de riesgo, información que el PDP promedio por sí solo no muestra.

9.3. Estabilidad de LIME

LIME (*Local Interpretable Model-agnostic Explanations*) ajusta, para una instancia x , un modelo sustituto local g interpretable (lineal) que aproxima el comportamiento del modelo f en un entorno de x definido por una distribución de perturbaciones ponderada por proximidad π_x :

$$\xi(x) = \arg \min_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g),$$

con $\Omega(g)$ una penalización de complejidad. Al depender de un muestreo aleatorio de perturbaciones, dos ejecuciones de LIME sobre la misma instancia x pueden producir coeficientes g distintos. Se reejecuta LIME 6 veces sobre los mismos 3 casos denegados por escenario (6 casos en total) y se mide, para cada combinación caso-variable, la desviación típica del peso asignado (**peso_std**) entre las 6 repeticiones, usando los índices internos de LIME en lugar de parsear el texto de sus explicaciones.




Figura 34: Dispersión (barras de error) del peso asignado por LIME a cada variable, en 6 reejecuciones sobre el mismo caso.

- **es_centinela_pastdue** (variable centinela de historial de mora) es, con diferencia, la variable más inestable: **peso_std** medio de 0.0322 (máximo 0.0357), aproximadamente el triple que la siguiente variable en el ranking de inestabilidad, *N. impagos 90+ días* (**std** = 0.0106).
- En 9 de las 72 combinaciones caso-variable evaluadas (6 casos $\times$ 12 variables) el peso cambia de signo entre reejecuciones, siempre concentrado en variables de relleno del ranking (Ingreso ausente, Ratio de deuda, N. de hipotecas/líneas inmobiliarias) y nunca en las de mayor peso (impagos, utilización de crédito), que mantienen el signo estable en las 6 repeticiones.
- Esta inestabilidad, confirmada aquí de forma autónoma (el cotejo cuantitativo frente a SHAP se detalla en la sección anterior), refuerza la preferencia por SHAP como técnica principal de auditoría local, al ser determinista frente a un método muestreado.

9.4. Auditoría descriptiva de subgrupos por tramo de edad

El Reglamento europeo de Inteligencia Artificial clasifica los sistemas de *scoring* crediticio como sistemas de “alto riesgo”, lo que motiva revisar si la tasa de denegación se aleja de la tasa de impago real dentro de subgrupos poblacionales. El conjunto de datos no incluye ningún atributo protegido explícito; la edad es el proxy más cercano disponible, de modo que este análisis es una auditoría descriptiva sobre los 6 tramos decadales ya usados en el preprocesado (≤ 30 , 31-40, 41-50, 51-60, 61-70, > 70 años), no un análisis de equidad formal: no se calculan métricas estándar de *fairness* como *equalized odds*.




Figura 35: Tasa de denegación frente a tasa de impago real por tramo de edad, escenario simétrico (coste1) y asimétrico (coste10).

Cuadro 23: Tasa de denegación, tasa de impago real y coste medio por tramo de edad y escenario (test, $n = 21\,000$).

Escenario	Tramo de edad	n	Tasa denegación	Tasa impago real	Coste medio
coste1	≤ 30	1562	0.0397	0.1056	0.1005
coste1	31-40	3431	0.0426	0.0895	0.0871
coste1	41-50	4951	0.0329	0.0844	0.0774
coste1	51-60	4896	0.0178	0.0674	0.0639
coste1	61-70	3734	0.0075	0.0356	0.0351
coste1	> 70	2426	0.0054	0.0210	0.0198
coste10	≤ 30	1562	0.3720	0.1056	0.4424
coste10	31-40	3431	0.2874	0.0895	0.4223
coste10	41-50	4951	0.2371	0.0844	0.3882
coste10	51-60	4896	0.1544	0.0674	0.3409
coste10	61-70	3734	0.0809	0.0356	0.2132
coste10	> 70	2426	0.0523	0.0210	0.1447

- La denegación sigue la **dirección** del riesgo real (decrece con la edad) pero no su **magnitud**, sobre todo en los más jóvenes. Bajo el escenario asimétrico, el cociente $\text{tasa_denegación} / \text{tasa_impago_real}$ es 3.52 en el tramo ≤ 30 años, desciende hasta un mínimo de 2.27 en 61-70 años y repunta a 2.49 en > 70 ; entre 2.3 y 2.5 en los tramos de mayor edad, nunca tan bajo como el mínimo sugeriría a primera vista.
- Bajo el escenario simétrico el mismo patrón es mucho más débil y no monótono (cocientes entre 0.21 y 0.48), coherente con que ese escenario es casi trivial (apenas mejora sobre conceder a todos) y su señal de subgrupo es más ruidosa.
- Lectura honesta:** este patrón no demuestra discriminación causal. La edad puede actuar como variable proxy de factores no observados en el conjunto de datos (antigüedad crediticia, estabilidad laboral), y la señal es precisamente más fuerte en el escenario donde el modelo aporta más valor de negocio real (coste10). Se trata de una mini-auditoría de sesgo descriptiva, no de un análisis de equidad formal.

9.5. Síntesis de las cuatro técnicas

- La importancia a tres bandas (permutación, XGBoost nativo, subrogado) no cuenta la misma historia en los dos escenarios: en coste1 la permutación queda casi plana (0.0000–0.0022) mientras nativo y subrogado coinciden en *N. impagos 90+ días*; en coste10 permutación y subrogado coinciden en *Utilización de crédito revolving*, pero la importancia nativa de XGBoost no cambia entre escenarios porque no depende del umbral.

- El PDP en dos dimensiones confirma, con un método agnóstico independiente del subrogado, que el efecto de la edad sobre $P(\text{denegar})$ es aproximadamente el doble en presencia de historial de mora (0.0448 frente a 0.0888); la superficie de probabilidad es idéntica en ambos escenarios de coste, solo cambia dónde corta el umbral.
- LIME reejecutado 6 veces sobre el mismo caso produce pesos distintos, con `es_centinela_pastdue` como variable más inestable (`peso_std` medio 0.0322, hasta 3 veces la siguiente) y 9 de 72 cambios de signo, siempre en variables de relleno del ranking: confirma empíricamente la conveniencia de usar SHAP (determinista) como referencia principal de auditoría local.
- Los subgrupos por tramo de edad siguen la dirección del riesgo real pero no su magnitud, con un efecto mucho más marcado bajo coste asimétrico (cocientes 2.27–3.52) que bajo coste simétrico (0.21–0.48); es una auditoría descriptiva, no causal ni de equidad formal, dadas las limitaciones de muestreo declaradas al inicio de esta sección (2000–3000 filas para permutación y PDP/ICE, rejilla 15×15 para el PDP 2D, 3 casos por escenario para LIME).

10. Decisiones de diseño

Esta sección sistematiza, con criterio metodológico, las decisiones técnicas más relevantes del proyecto. Cada una se documentó comparando alternativas concretas frente a la evidencia numérica que las decidió, evitando así que una elección quede justificada solo por intuición. Se agrupan en ocho bloques: paradigma de modelado, arquitectura de umbrales, familia de modelo, preprocesado (imputación, tratamiento de outliers y de duplicados), protocolo de validación anti-fuga, definición del coste del escenario asimétrico, complejidad del árbol subrogado y diseño de la auditoría de explicabilidad (contrafactuales, SHAP local y técnicas adicionales del bloque de otras técnicas).

10.1. Metodología de documentación

Se consideran “decisiones cerradas” aquellas que (i) enfrentan al menos dos alternativas explícitas, (ii) se resuelven con una métrica cuantitativa comparable entre ellas y (iii) tienen impacto directo sobre el coste de negocio o sobre la fiabilidad de la auditoría. Bajo este criterio se documentan las 15 decisiones más importantes del proyecto, resumidas en las Tablas 24 y 25. El identificador (ID) es una referencia secundaria de trazabilidad interna; cada fila se explica por sí sola junto con la evidencia numérica que la respalda.

10.2. Resumen de las decisiones cerradas

Cuadro 24: Decisiones de diseño (I): paradigma de modelado, preprocesado y protocolo de validación.

ID	Decisión	Elección final (evidencia)
D-0.1	Supervisado vs. bandit contextual multibrazo	Supervisado XGBoost: coste de test en el escenario asimétrico = 0.3275 frente a ~ 0.359 del LinUCB por validación cruzada
D-0.2	Un modelo con dos umbrales vs. un modelo por escenario	Un único XGBoost re-umbralizado dos veces: las probabilidades <i>out-of-fold</i> (OOF) coinciden byte a byte entre escenarios ($\max \Delta = 0$)
D-0.3	Familia de modelo (lineal, red neuronal, árboles, bandit)	XGBoost gana en ambos escenarios; brecha frente a la regresión logística de 0.033 en el escenario asimétrico y de 0.0006 en el simétrico
D-1.1	Imputación de nulos (MonthlyIncome, NumberOfDependents)	Mediana condicionada al tramo de edad más indicador de ausencia (<i>missing not at random</i>) para el ingreso; moda (valor 0) sin indicador para el número de dependientes
D-1.2	Outliers y cola anómala de DebtRatio	Recalcular la variable tras imputar el ingreso, en vez de winsorizar la cola a ciegas: el estadístico de Kolmogorov–Smirnov entre la cola y la distribución sana baja de 0.9284 a 0.1671 (detalle en la Tabla 26)
D-1.4	División train / test	Partición estratificada 80/20 (84 000 / 21 000 filas) realizada <i>antes</i> de estimar cualquier parámetro, para evitar fuga de información
D-1.6	Filas duplicadas	Se conservan (331 en train, 101 en producción): sin un identificador único no puede probarse que sean un error de captura
D-2.1	Protocolo de validación (umbral y familia ganadora)	Validación cruzada de 5 particiones sobre probabilidades OOF de train; el conjunto de test se reserva íntegramente para el reporte final

Cuadro 25: Decisiones de diseño (II): coste del escenario asimétrico, subrogado y auditoría XAI.

ID	Decisión	Elección final (evidencia)
D-3.1	Umbral analítico vs. umbral empírico	Se opera con el umbral empírico: 0.4934 en el escenario simétrico (analítico 0.5000) y 0.0906 en el asimétrico (analítico $1/11 = 0.0909$)
D-3.2	Coste del escenario 2	Asimétrico, con $C_{FN} = 10 \times C_{FP}$ (errata del enunciado confirmada por el profesor); el cambio de umbral provoca 7279 cambios de decisión sobre el conjunto de producción
D-5.1	Complejidad del árbol subrogado	Dos árboles fijados por escenario: uno operativo (max_depth=5 , 23 hojas) que maximiza la fidelidad y uno de bolsillo (max_depth=3 , 8 hojas) legible para el cliente
D-6.1	Herramienta de contrafactuales	DiCE con método aleatorio (<i>random</i>), acoplado a un adaptador que traslada la frontera interna de decisión de DiCE al umbral de negocio real de cada escenario
D-6.2	Número de casos contrafactuales auditados	8 casos (2 por clase real $\times$ 2 escenarios): 2 contrafactuales plausibles en el escenario simétrico y 1 en el asimétrico
D-7.1	Instancias y explicador para SHAP local	Los mismos 8 casos que en la fila anterior, explicados con TreeExplainer , el método exacto y determinista para modelos de árboles
D-8.1	Técnicas de explicabilidad adicionales (bloque de otras técnicas)	Importancia por permutación, PDP/ICE (incluida interacción 2D), reejecuciones de LIME y auditoría descriptiva por subgrupos de tramo de edad

10.3. Formalización de las decisiones cuantitativas

Umbral óptimo bayesiano (D-0.2, D-3.1). La arquitectura de un único modelo con dos umbrales de decisión se apoya en el resultado clásico de decisión bayesiana con costes asimétricos: dado un clasificador probabilístico $\hat{p}(x) = P(y = 1 | x)$ y una matriz de costes con C_{FP} para el falso positivo y C_{FN} para el falso negativo, el umbral que minimiza el coste esperado es

$$\theta^* = \frac{C_{FP}}{C_{FP} + C_{FN}}.$$

Para el escenario simétrico ($C_{FP} = C_{FN} = 1$) el umbral analítico es $\theta^* = 0.5000$; para el asimétrico ($C_{FP} = 1$, $C_{FN} = 10$) es $\theta^* = 1/11 = 0.0909$. La decisión D-3.1 consiste en operar con el umbral hallado por búsqueda exhaustiva sobre el coste empírico en vez del analítico, dado que ambos resultan casi coincidentes (0.4934 vs. 0.5000 y 0.0906 vs. 0.0909), lo que certifica una buena calibración del modelo justo en la zona de decisión relevante para el negocio.

Coste esperado empírico (D-0.1, D-2.1). El coste que se minimiza para elegir familia de modelo y umbral es el coste medio empírico sobre las probabilidades OOF de train,

$$\hat{C}(\theta) = \frac{1}{n} \sum_{i=1}^n \left[C_{FP} \cdot \mathbf{1}\{y_i = 0, \hat{y}_i(\theta) = 1\} + C_{FN} \cdot \mathbf{1}\{y_i = 1, \hat{y}_i(\theta) = 0\} \right], \quad \hat{y}_i(\theta) = \mathbf{1}\{\hat{p}_i \geq \theta\},$$

evaluado exclusivamente con validación cruzada de 5 particiones (D-2.1), reservando el conjunto de test para una única evaluación final. Este mismo estadístico es el que separa a XGBoost del bandit LinUCB en D-0.1 (0.3275 frente a ~ 0.359) y a las familias de modelo entre sí en D-0.3.

Fidelidad del modelo subrogado (D-5.1). Sea $g(x)$ la decisión de la caja negra (XGBoost re-umbralizado) y $\tilde{g}(x)$ la del árbol subrogado que la imita. La fidelidad global y la fidelidad restringida a la clase minoritaria “denegar” se definen como

$$\text{Fid}_{\text{global}} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{\tilde{g}(x_i) = g(x_i)\}, \quad \text{Fid}_{\text{denegar}} = P(\tilde{g}(x) = 1 | g(x) = 1).$$

Bajo el fuerte desbalanceo de las decisiones de denegación, la fidelidad global satura cerca de su máximo incluso para un árbol degenerado que no aprende nada de la clase rara, por lo que la decisión D-5.1 exige reportar siempre $\text{Fid}_{\text{denegar}}$ y el F_1 de la clase “denegar” junto con la fidelidad global, y fijar dos profundidades de compromiso (`max_depth=5` y `max_depth=3`) en vez de una sola: el F_1 de la clase denegar del árbol operativo sube de 0.756 en el escenario simétrico a 0.844 en el asimétrico, evidencia de que la fidelidad del subrogado depende del propio umbral de negocio, no solo de la profundidad del árbol.

Valores de Shapley y elección del explicador (D-7.1). Para un modelo f y una instancia x , la descomposición aditiva de Shapley reparte la predicción entre las M variables de entrada,

$$f(x) = \phi_0 + \sum_{j=1}^M \phi_j(x),$$

donde ϕ_0 es el valor base (media del modelo sobre el conjunto de referencia) y $\phi_j(x)$ es el valor de Shapley atribuido a la variable j , la única atribución que satisface simultáneamente las propiedades de eficiencia (aditividad), simetría, nulidad y consistencia. La decisión D-7.1 fija **TreeExplainer** como explicador de referencia porque, al ser un algoritmo exacto para ensembles de árboles, calcula estos $\phi_j(x)$ sin aproximación ni varianza entre reejecuciones, a diferencia

de LIME; y reutiliza los mismos 8 casos ya auditados con contrafactuales (D-6.2) para que ambas auditorías – accionabilidad individual y atribución local – se contrasten sobre las mismas instancias.

10.4. Evidencia numérica de las decisiones de preprocesado

Las decisiones D-1.1 y D-1.2 se apoyan en dos hallazgos analíticos que se resumen a continuación.

El numerador corrupto de DebtRatio (D-1.2). La variable de endeudamiento presentaba una cola anómala por encima del percentil 97.5. En el 100 % de esas filas el ingreso mensual no era utilizable (nulo o degenerado), de modo que la fórmula del ratio conservaba el numerador crudo (deuda en unidades absolutas) en vez de dividir por un ingreso válido. Recalcular la variable tras imputar el ingreso – en lugar de winsorizar la cola sin diagnosticar su causa – es la decisión de mayor impacto analítico del preprocesado.

Cuadro 26: Efecto de recalcular DebtRatio sobre las filas con ingreso no utilizable.

Métrica	Antes de recalcular	Después de recalcular
Mediana en la cola ($DebtRatio > p_{97.5}$)	1152.0 (numerador crudo)	0.29 (ratio normal)
Estadístico KS (cola vs. distribución sana)	0.9284	0.1671
AUC univariante $DebtRatio \rightarrow$ target	0.5212	0.5531

Colapso de la multicolinealidad al tratar los centinelas 96/98 como ausentes (D-1.1).

Las tres columnas de días de retraso en el pago (*PastDue*) usaban los códigos 96 y 98 como valores centinela y no como conteos reales. Tratarlos como valores ausentes, en vez de como números literales, colapsa la multicolinealidad severa detectada entre las tres variables (Factor de Inflación de la Varianza, VIF).

Cuadro 27: VIF de las columnas *PastDue* antes y después de tratar los centinelas como ausentes.

Columna	VIF antes (centinela como número)	VIF después (centinela como ausente)
PastDue 30–59 días	40.9	~ 1.18
PastDue 60–89 días	71.7	~ 1.15
PastDue 90+ días	89.6	~ 1.17

El VIF máximo de todo el conjunto de variables tras el cambio es 1.91, muy por debajo del umbral de alerta habitual ($VIF = 5$), lo que permite mantener las tres columnas como *features* separadas sin necesidad de consolidarlas en un índice compuesto.

10.5. Hallazgos

- El modelo ganador (XGBoost) lo es por capacidad, no por paradigma: a igual familia lineal el bandit LinUCB iguala o supera ligeramente a la regresión logística por validación cruzada en el escenario asimétrico, pero XGBoost bate a ambos con un coste de test de 0.3275 (asimétrico) y 0.0634 (simétrico).
- Un único modelo con dos umbrales basta para cubrir los dos escenarios de negocio: el mismo XGBoost se reutiliza sin reentrenar (probabilidades OOF idénticas byte a byte, $\max |\Delta| = 0$) y solo cambia el umbral de decisión, de 0.4934 (simétrico) a 0.0906 (asimétrico).

- El escenario 2 es asimétrico ($C_{FN} = 10 \times C_{FP}$, errata del enunciado confirmada por el profesor) y su impacto es material: 7279 solicitantes del conjunto de producción cambian de decisión respecto a asumir coste simétrico.
- El recálculo de **DebtRatio** es la aportación analítica central del preprocesado: el 100 % de la cola anómala correspondía a ingreso no utilizable, la mediana del numerador crudo era 1152.0 frente a 0.29 en filas sanas, el estadístico KS baja de 0.9284 a 0.1671 y el AUC univariante mejora de 0.5212 a 0.5531.
- Tratar los centinelas 96/98 de las columnas de retraso de pago como valores ausentes colapsa la multicolinealidad: el VIF de las tres columnas cae de 40.9/71.7/89.6 a $\sim 1.18/1.15/1.17$ (VIF máximo global 1.91).
- El árbol subrogado revela dos personalidades de riesgo según el escenario de coste: el F_1 de la clase “denegar” sube de 0.756 (simétrico) a 0.844 (asimétrico); SHAP, en cambio, es idéntico entre escenarios porque comparten el mismo XGBoost – solo cambia el umbral que traduce la puntuación de riesgo en decisión.
- Las técnicas de explicabilidad adicionales (D-8.1) usan distintos tamaños de muestra por coste computacional: 2000 filas para PDP/ICE, 3000 filas con 10 repeticiones para la importancia por permutación y 6 reejecuciones por caso para medir la inestabilidad de LIME.

11. Reflexión final

El mismo XGBoost, sin reentrenar y con las mismas probabilidades *out-of-fold* (OOF) reproducidas byte a byte, cambia de **política de riesgo** –no de modelo– al desplazar el umbral de decisión de 0.4934 a 0.0906. El AUC de test es idéntico en los dos escenarios (0.8701), lo que constituye la confirmación cuantitativa de que se trata del mismo estimador re-umbralizado y no de un modelo distinto: toda la diferencia de comportamiento observada en esta sección procede exclusivamente del punto de corte aplicado sobre la misma puntuación de riesgo. Esa opacidad adicional de un modelo de árboles frente a uno lineal solo se justifica cuando el coste de negocio es asimétrico: el hueco de rendimiento frente a una regresión logística crece unas 27 veces, de 0.000631 (escenario simétrico) a 0.016988 (escenario asimétrico). La auditoría multi-técnica desarrollada a lo largo del trabajo –subrogado por reglas, contrafactuales, SHAP cotejado con LIME y un análisis descriptivo por subgrupos de edad– muestra además que tanto la fiabilidad de la explicación como lo que puede comunicársele a un solicitante denegado dependen del par *umbral-técnica* empleado, no únicamente de la precisión del modelo. Esta sección no ejecuta ningún análisis nuevo: relee críticamente los resultados de las secciones anteriores y los reorganiza alrededor de las cuatro preguntas centrales del enunciado.

Cuadro 28: Comparación de los dos escenarios de coste sobre el mismo estimador XGBoost

Escenario	C_{FN}/C_{FP}	Umbral óptimo	Umbral analítico	AUC test	Coste test
Simétrico	1	0.4934	0.5000	0.8701	0.0634
Asimétrico	10	0.0906	0.0909	0.8701	0.3275

El umbral analítico de referencia se obtiene minimizando el coste esperado bajo una matriz de costes C_{FP}, C_{FN} constante y una probabilidad de impago bien calibrada:

$$\theta^* = \frac{C_{FP}}{C_{FP} + C_{FN}}.$$

Para $C_{FP} = C_{FN} = 1$ esto da $\theta^* = 0.5000$; para $C_{FP} = 1$, $C_{FN} = 10$ da $\theta^* = 1/11 \approx 0.0909$. Que los umbrales empíricos obtenidos por búsqueda exhaustiva sobre las probabilidades OOF (0.4934

y 0.0906) resulten casi idénticos a sus contrapartidas analíticas es en sí mismo evidencia de que el modelo está razonablemente bien calibrado precisamente en la zona de la curva donde se toma la decisión, si bien el ajuste es más estrecho en el escenario asimétrico (diferencia de 0.0003) que en el simétrico (diferencia de 0.0066).

1. Cambio de comportamiento óptimo

- El umbral óptimo pasa de 0.4934 (simétrico) a 0.0906 (asimétrico); ambos casi coinciden con sus umbrales analíticos teóricos (0.5000 y $1/11 \approx 0.0909$), señal de buena calibración del modelo en la banda de decisión.
- La tasa de denegación en test sube de 2.38 % a 18.70 %; en producción, de 2.36 % a 18.53 % (un factor $\approx 7.9\times$). El coste medio en test pasa de 0.0634 a 0.3275.
- La mejora relativa frente a la política trivial de conceder a todos crece de 5.20 % a 51.01 %. El análisis PDP en dos dimensiones (superficie de probabilidad conjunta de edad y morosidad, sección correspondiente a las técnicas adicionales de explicabilidad) es idéntico en ambos escenarios porque es el mismo estimador; únicamente cambia por dónde corta cada umbral esa misma geometría de riesgo.
- En el conjunto de producción, 7 279 solicitantes pasan de concedido a denegado entre el escenario 1 y el escenario 2, y 0 solicitantes se mueven en sentido inverso: el desplazamiento del umbral es estrictamente más restrictivo y nunca libera crédito que antes se denegaba.

2. Compromiso entre rendimiento y explicabilidad

El coste esperado empírico que guía la elección de umbral y de familia de modelo se estima, para un umbral θ dado, como el promedio muestral de los costes de error sobre las n observaciones evaluadas:

$$\hat{C}(\theta) = \frac{1}{n} \sum_{i=1}^n \left[C_{FP} \cdot \mathbf{1}\{y_i = 0, \hat{y}_i(\theta) = 1\} + C_{FN} \cdot \mathbf{1}\{y_i = 1, \hat{y}_i(\theta) = 0\} \right],$$

donde $\hat{y}_i(\theta) = \mathbf{1}\{P(\text{impago} \mid x_i) \geq \theta\}$ es la decisión de denegar/conceder inducida por el umbral θ . Este es el criterio con el que se compararon las familias de modelo por validación cruzada de 5 pliegues sobre probabilidades OOF.

- Escenario simétrico: XGBoost apenas mejora a un modelo lineal (hueco de validación cruzada logística-XGBoost de solo 0.000631) y la mejora frente a conceder-a-todos es marginal (5.20 %); es un escenario con una curva de coste casi plana alrededor del óptimo, próximo a la trivialidad.
- Escenario asimétrico: el hueco crece a 0.016988 (unas 27 veces mayor) y la mejora relativa sube a 51.01 %; aquí el modelo aporta valor de negocio real y es donde pagar el coste de opacidad de un modelo de árboles boosted frente a uno lineal queda justificado.
- Esa opacidad se audita con cuatro técnicas independientes –árbol subrogado, contrafactuales generados con DiCE, valores de Shapley cotejados con LIME, y un análisis descriptivo por subgrupos de edad–; ninguna es suficiente por sí sola, cada una responde a una pregunta distinta: aproximación global interpretable, accionabilidad a nivel de solicitante, atribución local del *score*, y equidad descriptiva por grupo demográfico proxy.

Cuadro 29: Impacto en denegaciones y fidelidad del subrogado (clase *denegar*) por escenario

Escenario	Denegación test	Denegación producción	Fidelidad _{denegar} (operativo)	F1 _{denegar}
Simétrico	2.38 %	2.36 %	78.96 %	0.7562
Asimétrico	18.70 %	18.53 %	84.54 %	0.8439

3. Lecciones de la auditoría: fiabilidad y calidad de la explicación

El árbol subrogado se entrena para imitar la decisión de la caja negra (conceder/denegar bajo un umbral fijo), no el impago real, por lo que se puntúa por **fidelidad** frente a la caja negra y no por exactitud frente al target. Dado el fuerte desbalance de la clase *denegar* en el escenario simétrico, la fidelidad global es engañosa (un árbol degenerado que concede siempre alcanza fidelidad global alta sin haber aprendido nada); el indicador relevante es la fidelidad restringida a la clase *denegar* de la caja negra:

$$\text{Fidelidad}_{\text{denegar}} = \frac{|\{i : \hat{g}_i^{\text{subrogado}} = 1 \wedge \hat{g}_i^{\text{caja negra}} = 1\}|}{|\{i : \hat{g}_i^{\text{caja negra}} = 1\}|}.$$

- El árbol subrogado revela dos “personalidades de riesgo” según el escenario: en el simétrico domina el número de impagos a 90+ días (importancia 0.7155); en el asimétrico domina la utilización de crédito revolving (importancia 0.4914) –el árbol atiende a variables distintas según dónde se sitúe el umbral de negocio.
- La fidelidad del subrogado degenerado (una regla trivial) en la clase *denegar* es 0 % en **ambos** escenarios: no sirve como explicación en ninguno de los dos. El árbol operativo (con profundidad real) eleva esa fidelidad a 78.96 % (F1 = 0.7562) en el escenario simétrico y a 84.54 % (F1 = 0.8439) en el asimétrico –precisamente mejor en el escenario donde más importa, porque es donde el modelo aporta valor de negocio (véase Tabla 29).
- DiCE solo genera contrafactuales accionables en 4 de los 8 casos analizados (0 de 4 en las denegaciones fuertes, aquellas con probabilidad de impago muy por encima del umbral) y, de esos 4 generados, solo 3 resultan plausibles tras las comprobaciones de sanidad –poco accionable justo donde más se necesitaría explicar al cliente por qué se le deniega el crédito.
- La lectura correcta de un contrafactual depende de la clase real del solicitante: si el caso denegado es en realidad un falso positivo (no habría impagado), el contrafactual es una explicación literal y accionable (“si su variable X hubiera sido Y , se le habría concedido el crédito”). Si el caso denegado es un acierto del modelo (impago real), el contrafactual –cuando existe– tiene valor de auditoría interna del comportamiento del modelo, pero no debería comunicarse al cliente como garantía de que modificar esa variable revertiría la decisión.

El explicador utilizado para la atribución local es **TreeExplainer**, que calcula de forma exacta los valores de Shapley para modelos de árboles. El valor de Shapley de la variable i para una instancia x , respecto de un modelo f y del conjunto completo de variables N , se define como

$$\phi_i(f, x) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [f_x(S \cup \{i\}) - f_x(S)],$$

es decir, la contribución marginal media de la variable i promediada sobre todos los órdenes posibles de entrada de las variables; los ϕ_i suman exactamente la diferencia entre la puntuación de la instancia (en escala log-odds, la escala aditiva nativa del margen de XGBoost) y el valor base del modelo, lo que garantiza aditividad exacta y evita atribuir a las variables más o menos peso del que realmente explica la predicción.

- SHAP es determinista (desviación estándar 0 entre reejecuciones) y sirve de referencia; LIME es inestable (desviación estándar media del peso asignado ≈ 0.0056 , máxima 0.0357) y cambia de signo en algunas combinaciones caso-variable, siempre en las variables de menor peso –las variables dominantes (impagos, utilización de crédito) mantienen signo estable en ambas técnicas.
- El acuerdo de *ranking* entre SHAP y LIME es solo moderado (correlación de Spearman en valor absoluto ≈ 0.49 , rango $[0.31, 0.60]$ sobre los 6 casos evaluados) y la variable más importante coincide en apenas 2 de 6 casos: SHAP es la referencia más fiable para auditar decisiones individuales.
- Sesgo por edad bajo el escenario asimétrico: los solicitantes de 30 años o menos son denegados a una tasa 3.52 veces superior a su tasa real de impago, frente a 2.27–2.49 veces en los grupos de mayor edad. Esto **no** demuestra discriminación causal: la edad puede actuar como variable proxy de factores no observados (antigüedad crediticia, estabilidad laboral) que el conjunto de datos no recoge; es una auditoría de sesgo descriptiva, no un análisis de equidad formal con métricas del tipo *equalized odds*.

4. Limitaciones y líneas de mejora

- El coste real en producción no puede verificarse porque las etiquetas de impago no están disponibles; el único indicador medible directamente es la tasa de denegación, que ya reproduce el mismo salto observado en test (2.36 % $\rightarrow$ 18.53 %).
- El recalclo de la variable de endeudamiento (ratio deuda/ingreso) introduce un acoplamiento débil pero real con la edad: la correlación de Spearman pasa de +0.0289 a –0.0981 tras la recalibración (correlación de Pearson –0.0059, prácticamente nula), un coste honesto declarado explícitamente de la transformación aplicada en el preprocesado.
- Ese recalclo se verificó, de forma independiente al punto anterior, como libre de fuga de información entre train y test: la media absoluta de las variables escaladas es $\approx 6.83 \times 10^{-16}$ en train (cero de máquina, por construcción del escalador), 0.021086 en test y 0.014083 en producción –una diferencia de ≈ 14 órdenes de magnitud que confirma que el ajuste del escalador utilizó exclusivamente datos de entrenamiento.
- Limitación de ingeniería detectada al reproducir resultados: cargar el modelo serializado con una versión de la librería de *gradient boosting* distinta a la usada en el entrenamiento reconstruye mal un parámetro interno del modelo e infla las probabilidades predichas por un factor ≈ 5 (la tasa de denegación pasaría de 2.4 %/18.7 % a cifras cercanas al 25 %/85 %); se corrigió fijando la versión exacta de la librería en las dependencias del proyecto antes de ejecutar la auditoría.
- Líneas de mejora futuras: monitorizar el umbral 0.0906 cuando lleguen etiquetas reales de producción para recalibrarlo si el coste efectivo se desvía del estimado; ampliar la auditoría de subgrupos a otros atributos protegidos más allá de la edad; relajar las restricciones de accionabilidad de DiCE para que también proponga alternativas en las denegaciones fuertes; y sustituir o estabilizar LIME dada su inestabilidad frente a SHAP como método de atribución local.

En conjunto, el ejercicio muestra que rendimiento y explicabilidad no son ejes independientes en este problema: el mismo cambio de umbral que hace que el modelo aporte valor de negocio real (escenario asimétrico) es también el que hace más difícil generar contrafactuales accionables y el que concentra el sesgo por edad con mayor intensidad. Auditar con una sola técnica –por completa que parezca– habría dejado sin responder al menos una de las cuatro preguntas centrales del enunciado; la combinación de subrogado, contrafactuales, SHAP/LIME y análisis de subgrupos es la que permite, finalmente, decir con evidencia numérica qué cambia entre los dos escenarios

de coste, por qué se justifica el modelo más complejo en uno de ellos, y qué se le puede decir –con honestidad– a un solicitante al que se le deniega el crédito.

Referencias

- [1] Lundberg, S. M. y Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. Advances in Neural Information Processing Systems (NeurIPS).
- [2] Ribeiro, M. T., Singh, S. y Guestrin, C. (2016). “*Why Should I Trust You?*” *Explaining the Predictions of Any Classifier*. KDD.
- [3] Mothilal, R. K., Sharma, A. y Tan, C. (2020). *Explaining Machine Learning Classifiers through Diverse Counterfactual Explanations (DiCE)*. FAccT.
- [4] Chen, T. y Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. KDD.
- [5] Molnar, C. (2022). *Interpretable Machine Learning*. 2^a ed.
- [6] Elkan, C. (2001). *The Foundations of Cost-Sensitive Learning*. IJCAI.