


Explicabilidad en la concesion de credito

Construir, optimizar y **auditar** un modelo de scoring bajo dos politicas de coste. El coste de los errores fija el umbral de decision; la auditoria (subrogado, contrafactuales, SHAP) explica cada decision. Un unico XGBoost sirve a los dos escenarios: solo cambia donde se corta.



Grupo: **Oscar Romero Quincoces · Fernando Dapena Tauste · Daniel Garcia Lopez**

Entrega 20 de julio de 2026 · entregables: informe + cs_produccion1.csv (simetrico) y cs_produccion2.csv (asimetrico)

CONTENIDO

1. Datos y analisis exploratorio
2. Preprocesado
3. Modelo: escenario de coste simetrico
4. Modelo: escenario de coste asimetrico
5. Comparativa entre escenarios
6. Auditoria: modelo subrogado
7. Auditoria: contrafactuales
8. Auditoria: SHAP y cotejo con LIME
9. Otras tecnicas de explicabilidad
10. Decisiones de diseno
11. Reflexion final

Datos y analisis exploratorio

Antes de modelar se valida que el conjunto de entrenamiento y el de producción comparten esquema, y se caracteriza a fondo el conjunto de entrenamiento: desbalance de la variable objetivo, valores centinela de codificación, outliers, correlaciones, multicolinealidad y el mecanismo de ausencia de las dos únicas variables con valores nulos. Este diagnóstico es el que determina, en la sección siguiente, cómo se imputa y se limpia cada variable.

105.000

Filas train ·
cs_construccion.csv (8,81 MB)

45.000

Filas producción ·
cs_produccion.csv (3,78 MB,
sin target)

6,6838%


Tasa de clase 1 (impago) ·
desbalance ~1 de cada 15

19,8048%


Nulos en MonthlyIncome
(train)

92,30


VIF máximo bruto (PastDue,
antes de tratar centinelas)



Qué mirar: la altura desigual de las dos barras —93,3162% clase 0 frente a 6,6838% clase 1— confirma un desbalance manejable, sin necesidad de remuestreo agresivo antes de modelar.




Qué mirar: la tasa de impago es más baja cuando MonthlyIncome es nulo (5,4917%) que cuando es conocido (6,9782%) —un resultado contraintuitivo que descarta imputar y borrar sin más la señal de ausencia.




Qué mirar: el boxplot de DebtRatio se dispara cuando MonthlyIncome es nulo (mediana 1181, 0) frente al rango normal con ingreso conocido (mediana 0,2953): evidencia visual de que el campo guarda el numerador crudo de la deuda sin dividir.

Mecanismo de ausencia (MNAR). El nulo de MonthlyIncome no señala mayor riesgo, pero la diferencia de tasa de impago es sistemática, no aleatoria. El nulo de NumberOfDependents (2.738 filas, 2,6076%) es subconjunto exacto del nulo de MonthlyIncome: ese subgrupo es más mayor (edad mediana 61 frente a 52 años) y con menor tasa de impago (4,6749% frente a 6,7376%). Ambas ausencias comparten el mismo mecanismo no aleatorio, compatible con clientes mayores con menos datos financieros registrados: mejor preservarlas con una variable indicadora que imputar y borrar la señal.



Qué mirar: solo las tres columnas PastDue superan el umbral de multicolinealidad severa ($VIF > 10$): 92,30 / 73,68 / 41,29; el resto de variables se mantiene por debajo de 1,3.



Qué mirar: el bloque de correlación casi perfecta (~0,98–0,99) entre las tres columnas PastDue, que más adelante resulta inflado: el Spearman real entre ellas cae a 0,25–0,32.

Variable	VIF
NumberOfTime60-89DaysPastDueNotWorse	92,30
NumberOfTimes90DaysLate	73,68
NumberOfTime30-59DaysPastDueNotWorse	41,29
NumberOfOpenCreditLinesAndLoans	1,29
NumberRealEstateLoansOrLines	1,27
age	1,09
NumberOfDependents	1,08
DebtRatio	1,02
MonthlyIncome	1,02
RevolvingUtilizationOfUnsecuredLines	1,00

HALLAZGOS

- Desbalance manejable (~1 de cada 15 clientes en clase 1): 93,3162% clase 0 (97.982 filas) frente a 6,6838% clase 1 (7.018 filas).
- Esquema y nulos casi idénticos entre train y producción, con la única diferencia esperada (dtype del target, vacío en producción): MonthlyIncome 19,8048% frente a 19,8578%; NumberOfDependents 2,6076% frente a 2,6356%.
- DebtRatio guarda el numerador crudo de deuda sin dividir cuando falta el ingreso: mediana 1181,0 frente a 0,2953 con ingreso conocido (3.999,32 veces mayor), y el 93,912% de esas filas tiene DebtRatio>1 frente a solo 6,0151% en el resto: un artefacto de cálculo, no variabilidad real.
- El VIF severo de las tres columnas PastDue está inflado por 188 filas centinela (código 96/98 simultáneo, 0,1790% del dataset) con tasa de impago del 54,26% —8 veces el 6,60% del resto—; un análisis de robustez sin centinelas ni outliers extremos confirma que la separación entre clases no mejora al retirarlos.

Preprocesado

El split 80/20 estratificado se fija antes de aprender cualquier parámetro: imputación, recálculo de *DebtRatio*, winsorizado y escalado se ajustan únicamente con las 84.000 filas de train y se aplican, sin volver a ajustarse, sobre test y producción. El hallazgo central es que el fichero original guardaba en *DebtRatio* el numerador crudo de deuda -no el ratio- cuando el ingreso no era utilizable; dividir por el ingreso ya imputado corrige la variable. Todo el pipeline queda encapsulado en una clase

PreprocesadorCredito certificada por una batería de 9 asserts frente a fuga de información.

**84.000 /
21.000**

Filas train / test (split 80/20 estratificado)

**17.900
(21,31%)**

Filas con ingreso no usable (nulo o ≤ 1)

**0,9284 →
0,1671**

KS de *DebtRatio*: antes → después del recálculo

**0,5212 →
0,5531**

AUC univariante de *DebtRatio*: antes → después

1,9065


VIF máximo final del pipeline (*DebtRatio*)

9 (A-I)


Asserts que certifican el pipeline sin fuga

El split preserva el desbalance real (6,6833% de clase positiva en train frente a 6,6857% en test, a solo 0,0024 puntos de distancia). Sobre train se sigue un orden fijo de limpieza: se corrige 1 fila con `age==0`, se tratan como *missing* los valores centinela 96/98 simultáneos en las tres columnas de morosidad (149 filas, 0,1774%), se imputa *MonthlyIncome* por la mediana del tramo de edad y, por último, se imputa *NumberOfDependents* por su moda (0). El desbalance de clases no se corrige aquí: remuestrear antes del split introduciría fuga, así que se delega a la fase de modelado vía peso de clase o umbral por coste.

Conjunto	Filas	Positivos (impago)	Negativos	Tasa clase positiva
Train	84.000	5.614	78.386	6,68%
Test	21.000	1.404	19.596	6,69%
Total	105.000	7.018	97.982	6,68%




Qué mirar: cómo la distribución de *DebtRatio* en las filas con ingreso no usable pasa de dispararse (numerador crudo sin dividir) a solaparse con el rango normal tras dividir por el ingreso ya imputado.



Qué mirar: el gradiente real en forma de U invertida por tramo de edad frente al valor global único (5.460 €) que habría colapsado las 17.900 filas nulas en un pico artificial.


El recálculo de *DebtRatio* confirma la hipótesis del EDA: la mediana de las filas con ingreso no usable pasa de 1.152,0 (numerador crudo) a 0,2050 tras dividir por el ingreso imputado, muy cerca de la mediana de las filas usables (0,2902); el KS de dos muestras (contaminada vs. sana) cae de 0,9284 a 0,1671 y el AUC univariante de *DebtRatio* frente al target sube de 0,5212 a 0,5531. El 100% de la cola por encima del percentil 97,5 (2.100 filas, umbral 3.538,03) correspondía a ingreso no usable.

Los 17.900 casos de ingreso no usable combinan 16.695 nulos y 1.205 con ingreso ≤ 1 ; un test χ^2 frente al target confirma que ambos subgrupos son estadísticamente distintos entre sí ($\chi^2=6,8716$, $p=0,008758$). Aun así se fusionan en un único indicador *is_missing_monthlyincome* porque comparten el mismo mecanismo de origen -el numerador de deuda corrupto-, no la misma tasa de riesgo: es una decisión de honestidad metodológica, no un atajo de conveniencia.



Qué mirar: el histograma de *Revolving* antes del recorte (cola larga extrema, skew 63,10) frente a después de winsorizar al percentil 99 (cap 1,102904) + log1p + escalado, con forma casi simétrica (skew final 0,717). *DebtRatio* se recorta al percentil 99,9 (cap 9,184215); *age* deliberadamente no lleva log1p, porque su skew (0,1909) empeoraría a -0,4346 con la transformación.

El VIF severo de las tres columnas de morosidad detectado en el EDA (40,90 / 71,70 / 89,64) era un artefacto de las 149 filas centinela: al tratarlas como *missing*, el VIF colapsa a valores entre 1,15 y 1,18 y el Pearson máximo entre esas columnas baja de 0,9926 a 0,2995, por lo que las tres pueden entrar al modelo como variables separadas sin necesidad de consolidarlas en un índice. El VIF máximo de todo el pipeline final es 1,9065 (*DebtRatio*): sin multicolinealidad relevante.



Qué mirar: la media absoluta de las features en train queda en $\sim 6,83e-16$ (cero de máquina, porque el escalado se ajustó ahí) frente a 0,021086 en test y 0,014083 en producción: un salto de ~ 14 órdenes de magnitud que demuestra que el ajuste (*fit*) no vio ni test ni producción.

El contrato de salida entrega train (84.000×13), test (21.000×13) y producción (45.000×14 , con `id_fila_original` para trazabilidad): 10 variables continuas más 2 indicadores binarios (`is_missing_monthlyincome`, `es_centinela_pastdue`). La batería de 9 asserts (A-I) certifica, entre otras cosas, reproducibilidad exacta del objeto serializado, ausencia de NaN, apatridia por lote (mismo resultado fila a fila), invarianza al orden de las filas y robustez ante valores de producción no vistos -por ejemplo, un `Revolving=50.708` se recorta correctamente al cap 1,102904-.

HALLAZGOS

- El indicador `es_centinela_pastdue` dispara la tasa de impago a 53,69% frente al 6,60% del resto (~8x), confirmando que las 149 filas centinela no son ruido de captura sino señal real.
- El recálculo de *DebtRatio* mejora el KS de 0,9284 a 0,1671 y el AUC univariante de 0,5212 a 0,5531, con la mediana de las filas no usables cayendo de 1.152,0 a 0,2050.
- El VIF de las tres columnas de morosidad pasa de 40,90/71,70/89,64 a ~1,2 al tratar los 149 centinelas como *missing*; el VIF máximo de todo el pipeline es 1,9065.
- La auditoría de fuga muestra una media absoluta de features de ~6,83e-16 en train frente a 0,021086 en test y 0,014083 en producción, reforzada por los 9 asserts (A-I) que incluyen apatridia por lote e invarianza a permutación.
- Nota de calidad de datos: 107 filas de test (0,51%) tienen una fila "gemela" exacta en train (idénticas en las 10 variables originales y en el objetivo); el impacto práctico en el escenario de coste simétrico es prácticamente nulo, pero se deja constancia explícita de la existencia de duplicados repartidos entre particiones.
- Decisión explícita de diseño: el desbalance de clases (6,68%) no se corrige en el preprocesado, porque remuestrear antes de fijar el modelo introduciría fuga de información; se delega a la fase de modelado mediante `class_weight` o ajuste del umbral de decisión por coste (secciones 5 y 6).

Modelo: escenario de coste simetrico

Bajo el escenario de coste simetrico (denegar a un buen cliente y conceder a un moroso cuestan igual, $C_{FP} = C_{FN} = 1$) se comparan cinco familias de modelos por validacion cruzada con probabilidades *out-of-fold*, sin reponderar clases: la respuesta a un coste asimetrico es mover el umbral, no distorsionar la probabilidad. Gana XGBoost por un margen minimo y su umbral optimo practicamente coincide con el analitico (0.5), senal de que este escenario es poco exigente.

0.4934

Umbral optimo (CV,
XGBoost)

0.5000

Umbral analitico
 $C_{FP}/(C_{FP}+C_{FN})$

0.0634

Coste medio en test

5.20%

Mejora vs. conceder a todos


0.8701

AUC en test


2.36%

Tasa de denegacion en
produccion

Se enfrentan cinco familias con interfaz comun `predict/predict_proba` -logistica, XGBoost, una MLP pequena, una MLP profunda y el bandit contextual LinUCB- todas sin SMOTE ni `class_weight`. La comparacion usa CV(5) estratificado y las probabilidades OOF concatenadas de **train** (nunca las de test, para no contaminar el numero que luego se reporta). El umbral operativo sale de una busqueda exhaustiva del coste sobre esas probabilidades y se contrasta con el umbral analitico $C_{FP}/(C_{FP}+C_{FN}) = 0.5$.




Que mirar: lo plana que es la curva de coste y lo cerca que cae el optimo empirico (0.4934) de la vertical analitica (0.5).




Que mirar: el fuerte solapamiento entre clases alrededor del umbral, que explica por que el modelo cuesta poco pero tiene recall bajo.

Modelo	Familia	Coste CV	Umbral	Denegacion CV
XGBoost	boosted	0.0623	0.4934	2.33%
MLP pequena	neuronal	0.0624	0.4891	2.01%
MLP profunda	neuronal	0.0626	0.4759	1.85%
Logistica	lineal	0.0629	0.4837	2.05%
LinUCB	bandit	0.0629	-	2.14%
Conceder a todos	baseline	0.0668	-	0.00%
Denegar a todos	baseline	0.9332	-	100.00%



Que mirar: el ganador (azul) frente a la línea punteada de conceder a todos; todas las barras quedan por debajo de esa referencia.

F4 - Confusion en test (umbral=0.4934)



Que mirar: los falsos negativos (1118) superan con creces a los falsos positivos (213), coherente con un recall bajo.

El bandit LinUCB, con la misma capacidad lineal que la regresión logística, prácticamente empata con ella (0.0629 frente a 0.0629). La ventaja de XGBoost viene de la capacidad del *boosting*, no del hecho de ser un método supervisado; se elige por auditabilidad y por ofrecer una probabilidad calibrada, sin el *regret* de exploración propio de un bandit.

HALLAZGOS

- Gana XGBoost con $\text{coste_cv} = 0.062286$; le siguen MLP pequena (0.062440), MLP profunda (0.062619), logistica (0.062917) y LinUCB (0.062929): la familia casi no importa en este escenario, el hueco entre logistica y XGBoost es de solo 0.000631.
- El umbral optimo OOF (0.4934) es practicamente igual al analitico (0.5): la curva de coste es casi degenerada, sintoma de un escenario poco exigente frente al asimetrico de la seccion siguiente.
- En test, el coste del ganador (0.063381) mejora un **5.1994%** sobre conceder a todos (0.066857) y queda muy por debajo de denegar a todos (0.933143); precision = 0.5731, recall = 0.2037, AUC = 0.8701 (TN 19383, FP 213, FN 1118, TP 286).
- Un *bootstrap* pareado (B = 5000, semilla 42) confirma que la mejora es pequena pero significativa: edge medio = 0.003476 (5.20% del coste del baseline), IC95% = [0.001381, 0.005571], $P(\text{edge} \leq 0) = 0.0008$.
- La transferencia de test a produccion es estable: distancia KS = 0.0118 (despreciable) y tasas de denegacion casi identicas (2.3762% en test vs 2.3556% en produccion). El entregable [cs_produccion1.csv](#) deniega credito al **2.3556%** de los solicitantes (1060 de 45000), coherente con un escenario simetrico que deniega poco.

Modelo: escenario de coste asimétrico

Se reutiliza, sin reentrenar, el mismo XGBoost y las mismas probabilidades OOF del escenario simétrico: bajo un coste asimétrico no hace falta un modelo nuevo, solo mover el umbral de decisión. Aquí un falso negativo (conceder crédito a un moroso) cuesta **10 veces** más que un falso positivo (denegar a un buen pagador): $C_{FP} = 1$, $C_{FN} = 10$.

0.0906

Umbral óptimo empírico

0.0909

Umbral analítico (1/11)

0.3275

Coste medio en test


51.01%

Mejora vs. conceder-todo


18.70%

Tasa de denegación en test

El umbral óptimo cae de 0.4934 (escenario simétrico) a 0.0906, prácticamente idéntico al óptimo analítico teórico $C_{FP} / (C_{FP} + C_{FN}) = 1/11 = 0.0909$. Con un único modelo y dos umbrales de decisión distintos se cubren ambos escenarios de negocio: solo cambia el punto de corte que se aplica sobre la misma puntuación de riesgo.




Qué mirar: el mínimo de la curva de coste OOF (punto rojo, 0.0906) casi encima de la vertical analítica (0.0909); la diferencia de coste entre usar uno u otro umbral es de solo ~0.0008.



Qué mirar: cómo el umbral se desplaza mucho hacia la izquierda al encarecer el falso negativo, ampliando con fuerza la zona de denegación frente al escenario simétrico.


Además del umbral, se recompensa por validación cruzada la familia ganadora (logística, XGBoost y el bandit contextual LinUCB reentrenado con la nueva recompensa) para comprobar si la asimetría de costes cambia quién gana. A diferencia del escenario simétrico -donde el gap entre familias era casi ruido-, aquí la capacidad del modelo sí importa.

Familia	Modelo	Coste CV	Tasa denegación CV	Mejora vs. conceder-
Boosted	XGBoost	0.3344	18.37%	49
Bandit	LinUCB	0.3502	16.64%	47
Lineal	Logística	0.3513	18.04%	47
Baseline	Conceder todo	0.6683	0.00%	6
Baseline	Denegar todo	0.9332	100.00%	-39



Qué mirar: XGBoost (0.3344) separado con claridad de logística y LinUCB (~0.35), un gap de 0.0170 muy superior al que separaba a las familias en el escenario simétrico.

F5 - Confusion en test: al encarecer el FN, baja FN y sube FP



Qué mirar: el trasvase entre errores al pasar de simétrico a asimétrico: los falsos negativos bajan de 1118 a 396 y los falsos positivos suben de 213 a 2918.

La matriz de confusión en test se reequilibra al encarecer el falso negativo: **FN baja de 1118 a 396** y **FP sube de 213 a 2918**, el trasvase exacto que impone penalizar diez veces más conceder crédito a un moroso. El modelo ganador con el umbral asimétrico alcanza en test precisión=0.2568, recall=0.7179 y AUC=0.8701 -el AUC no cambia porque el scoring es el mismo; solo cambia el punto de corte-.

La tasa de denegación sube de 2.38% a 18.70% en test (21000 solicitantes) y, aplicando el mismo umbral en producción (45000 solicitantes sin etiqueta), de 2.36% (1060) a 18.53% (8339): 7279 solicitantes pasan de concedido a denegado y 0 en sentido inverso, porque el umbral asimétrico es estrictamente más bajo y sus denegaciones incluyen todas las del escenario simétrico.

HALLAZGOS

- El umbral óptimo empírico (0.0906) casi coincide con el analítico teórico $1/11=0.0909$: el scoring está bien calibrado justo en la banda de decisión, y el mínimo de coste es plano (diferencia de solo ~ 0.0008 entre ambos umbrales).
- Con asimetría el modelo aporta valor de negocio real: el coste en test baja de 0.6686 (conceder-todo) a 0.3275 , una mejora relativa del 51.01% , muy por encima del 5.20% logrado en el escenario simétrico, y ambos muy por debajo del coste de denegar-todo (0.9331).
- Aquí la familia de modelo sí importa: por validación cruzada, XGBoost ($\text{coste_cv}=0.3344$) bate a logística (0.3513) y al bandit LinUCB (0.3502) por un gap de 0.0170 ; el bandit iguala aproximadamente a la logística (misma capacidad lineal), así que la ventaja de XGBoost viene de su capacidad de boosting, no del mero hecho de ser supervisado.
- La tasa de denegación sube de 2.38% a 18.70% en test y, en producción, de 2.36% (1060) a 18.53% (8339): 7279 solicitantes pasan de concedido a denegado y ninguno en sentido inverso.

Comparativa entre escenarios

Se comparan los dos escenarios de coste contruidos sobre el **mismo modelo supervisado ganador** (XGBoost): el escenario simetrico ($C_{FP}=C_{FN}=1$) frente al asimetrico ($C_{FP}=1$, $C_{FN}=10$, donde conceder credito a un moroso pesa diez veces mas que denegarselo a un buen pagador). El modelo no cambia entre escenarios: solo se desplaza el umbral de decision sobre la misma probabilidad estimada.

0.8701

AUC test — identico en ambos escenarios

0.4934

Umbral optimo, escenario simetrico

0.0906

Umbral optimo, escenario asimetrico

2.36%


Denegacion en produccion (simetrico)

18.53%

Denegacion en produccion (asimetrico)


7279

Solicitantes que pasan de concedido a denegado (16.2%)




Que mirar: el mismo XGBoost, sin reentrenar, produce costes y tasas de denegacion muy distintos segun donde se fije el umbral (0.4934 frente a 0.0906); la barra de **coste** cae con fuerza al pasar al escenario asimetrico porque penalizar mas el falso negativo evita mas impagos costosos.

F4 - Confusion en test (umbral=0.4934)



Que mirar: con el umbral relajado (0.4934) los falsos negativos (1118) superan con creces a los falsos positivos (213): el modelo apenas deniega y deja pasar impagos.

F5 - Confusion en test: al encarecer el FN, baja FN y sube FP



Que mirar: al bajar el umbral a 0.0906 el reparto se invierte -los falsos negativos caen a 396 y los falsos positivos suben a 2918-, el trasvase exacto que impone penalizar diez veces mas conceder credito a un moroso.

Escenario	Umbral optimo	Coste test	Coste conceder-todo	De
Simetrico ($C_{FP}=C_{FN}=1$)	0.4934	0.0634	0.0669	
Asimetrico ($C_{FN}=10 \cdot C_{FP}$)	0.0906	0.3275	0.6686	

El coste real en produccion no se calcula aqui: las etiquetas de `cs_produccion1.csv` y `cs_produccion2.csv` (45000 solicitudes cada uno) estan ocultas y esa evaluacion corresponde al profesor. Como proxy observable se muestra la **tasa de denegacion**, calculada sobre la decision predicha (0=concedido, 1=denegado) que el modelo escribe en esos ficheros -no sobre un target real-.

HALLAZGOS


- **1.** El AUC de test es idéntico en los dos escenarios (0.8701): prueba cuantitativa de que es el mismo modelo re-umbralizado, no un reentrenamiento distinto. Los umbrales óptimos (0.4934 y 0.0906) caen muy cerca de sus valores analíticos teóricos (0.5 y $1/11=0.0909$).
- **2.** El equilibrio FN/FP se invierte con fuerza: los falsos negativos caen de 1118 a 396 y los falsos positivos suben de 213 a 2918 (recall $0.204 \rightarrow 0.718$, precisión $0.573 \rightarrow 0.257$) - el modelo se vuelve mucho más conservador al conceder crédito cuando el impago no detectado cuesta diez veces más.
- **3.** La mejora relativa frente a conceder-a-todos escala fuerte con la asimetría: 5.20% en el escenario simétrico frente a 51.01% en el asimétrico, con la misma familia ganadora en ambos; el coste de denegar-a-todos es idéntico en los dos casos (0.9331) porque no depende de C_{FN} .
- **4.** La tasa de denegación en producción confirma la tendencia de test: 2.36% (1060/45000) en el escenario simétrico frente a 18.53% (8339/45000) en el asimétrico. Unos 7279 solicitantes (16.2% del total) pasan de concedido a denegado al endurecer el umbral, y ninguno en sentido inverso.

Auditoria: modelo subrogado


Un arbol de decision superficial (DecisionTreeClassifier) se entrena para **imitar** - no para predecir el impago real- las decisiones de conceder o denegar que toma XGBoost bajo cada umbral de coste, y se evalua por **fidelidad** frente a la caja negra, nunca por acierto frente al target verdadero. Para cada escenario se fijan dos arboles: uno **operativo** (profundidad 5, 23 hojas) que maximiza la fidelidad para auditar el modelo, y uno de **bolsillo** (profundidad 3, 8 hojas) legible de un vistazo para explicar la decision a un cliente. El barrido de profundidad revela que la fidelidad global es enganosa bajo el fuerte desbalance de denegaciones, y que el subrogado destila dos personalidades de riesgo distintas segun donde se fija el umbral de coste.

98,79%Fidelidad global, operativo
coste1**78,96%**Fidelidad clase «denegar»,
coste1**94,15%**Fidelidad global, operativo
coste10**84,54%**Fidelidad clase «denegar»,
coste10**97,62%**Trampa: arbol degenerado
«conceder siempre»
(fid_denegar = 0%)

Se barre la profundidad del arbol (2 a 10) y el peso de la clase «denegar», porque bajo el fuerte desbalance del escenario simetrico (solo 2,38% de denegaciones) un arbol trivial que concediera siempre alcanzaria un 97,62% de fidelidad global sin haber aprendido nada de cuando se deniega: hay que mirar la fidelidad de la clase rara, no solo la global. Los umbrales de las reglas resultantes ya estan traducidos a euros, anios y ratios reales -no a la escala estandarizada- gracias al pipeline de preprocesado.




Que mirar: la fidelidad global (linea superior) satura casi plana en torno a 0,98 desde poca profundidad, mientras que la fidelidad y el F1 de la clase **denegar** siguen mejorando con la profundidad y dependen fuertemente del peso de clase: ahi esta el limite real de aprendizaje del subrogado, no en la fidelidad global.




Que mirar: la raiz del arbol de bolsillo, escenario simetrico (umbral 0,4934, deniega al 2,38%): corta por impagos ya consumados de 90 dias o mas, un criterio **conservador**.

Arbol de bolsillo - asimetrico (coste10, depth 3)



Que mirar: la raiz del arbol de bolsillo, escenario asimetrico (umbral 0,0906, deniega al 18,70%): corta por la utilizacion de credito revolving, una senal de estres temprano, un criterio **preventivo**. Es el mismo XGBoost; solo cambia donde se fija el umbral.

Arbol subrogado - escenario asimetrico (coste10, depth 5)



Que mirar: el arbol operativo completo (23 hojas, coste10): con mas profundidad se despliega toda la jerarquia de la variable dominante -utilizacion de credito revolving- combinada con moras y edad. De estas ramas salen, una por una, las reglas de denegacion listadas a continuacion.

Subrogado	N. hojas	Deny caja negra	Deny subrogado	Fidelidad
Coste1 operativo (d5)	23	2,38%	2,59%	
Coste1 bolsillo (d3)	8	2,38%	3,53%	
Coste10 operativo (d5)	23	18,70%	18,76%	
Coste10 bolsillo (d3)	8	18,70%	11,96%	

Reglas de denegacion destiladas. Se extraen directamente de las ramas del arbol operativo de 23 hojas que terminan en *denegar*, con los umbrales ya traducidos a euros, años y ratios reales. En el escenario simetrico, 8 reglas cubren 543 de las denegaciones de test; la regla principal (soporte 118, pureza 100%) deniega cuando el numero de impagos de 90 dias o mas es 2 o superior, las moras de 60-89 dias son 2 o mas y la utilizacion de credito revolving supera el 91%. En el escenario asimetrico, 18 reglas cubren 3.940 denegaciones; la regla principal (soporte 975, pureza 100%) deniega cuando la utilizacion revolving supera el 77%, las moras de 30-59 dias son 2 o mas, la edad es de 63,5 años o menos y el ingreso mensual no supera los 12.506,50 EUR. Dentro de las reglas del escenario simetrico aparece ademas una interaccion edad x mora: a igual perfil de impagos graves (2 o mas) y moras 60-89 (1 o menos) con moras 30-59 dias en 2 o mas, los solicitantes de mas de 43,5 años caen a una pureza del 75,0% (soporte 58) frente al 98,0% (soporte 53) de los menores de esa edad.

Nota de reproducibilidad: al recargar el XGBoost serializado (.joblib) con una version de la libreria distinta a la de entrenamiento, el parametro interno `base_score` se reconstruia mal e inflaba las probabilidades por 5 -habria denegado al 25%/85% en vez del 2,4%/18,7% real-. Se detecto y corrigio fijando la version exacta de la libreria antes de esta auditoria, garantizando que las cifras anteriores correspondan al modelo realmente entrenado.

HALLAZGOS

- La fidelidad global engaña bajo desbalance: un árbol degenerado que «concediera siempre» en `coste1` alcanzaría 97,62% de fidelidad global con `fid_denegar = 0%`; el operativo real sube el global a 98,79% y además la fidelidad de la clase denegar a 78,96% ($F1 = 0,7562$): hay que mirar siempre la clase rara, nunca el global aislado.
- El peso óptimo de la clase «denegar» depende del escenario: 3 en `coste1` (clase rara, 2,38% de denegaciones) frente a sin reponderar en `coste10` (clase frecuente, 18,70%); en ambos casos el operativo reproduce casi exacta la tasa real de denegación de la caja negra (2,59% vs 2,38% en `coste1`; 18,76% vs 18,70% en `coste10`), un chequeo de sanidad independiente del $F1$.
- Dos personalidades de riesgo: la variable dominante se invierte entre escenarios -N. impagos 90+ días (importancia 0,7155) en `coste1` frente a utilización de crédito revolving (importancia 0,4914) en `coste10`, donde los impagos 90+ caen al tercer puesto (0,1875)-. Mismo XGBoost, lógica de decisión opuesta según donde se fija el umbral de coste.
- El árbol de bolsillo (8 hojas) cubre el 83,97% de las denegaciones reales en `coste1` pero solo el 59,88% en `coste10`: con más denegaciones que explicar (18,70% vs 2,38%), 8 hojas resultan un techo estructural insuficiente, y la brecha de $F1$ frente al operativo es mayor en `coste10` (-0,11) que en `coste1` (-0,08).

Auditoria: contrafactuales

Se seleccionan 8 solicitudes denegadas (2 por clase real x 2 escenarios de coste) para buscar, con DiCE, un contrafactual accionable que respete el umbral de negocio real de cada escenario. El resultado distingue con nitidez entre casos **borde_umbral**, donde siempre aparece una alternativa razonable, y casos de **denegacion_fuerte**, donde ninguna combinacion de cambios revierte la decision.

La busqueda se restringe a 4 variables accionables -utilizacion de credito revolving, ratio de deuda, ingresos mensuales y numero de lineas de credito abiertas- con limites realistas por solicitante: ingresos hasta +25%, revolving y DebtRatio hasta -30%, cierre de hasta dos lineas de credito. El resto de variables (edad, historial de impagos, personas dependientes) queda fijo. Cada candidato pasa 6 comprobaciones (rango observado, ausencia de negativos, inmutables sin cambios, direccion favorable, conteos enteros y decision realmente invertida) antes de traducirse a una frase para el cliente.

4/4

Contrafactual generado en casos borde_umbral

0/4

Contrafactual generado en denegacion_fuerte

3/4


Contrafactuales plausibles del total generado

0,4934

Umbral de decision, escenario coste1

0,0906

Umbral de decision, escenario coste10



Que mirar: la figura solo representa los 3 casos con contrafactual generado y plausible (2 puntos en el panel coste1, 1 en el panel coste10); no incluye los 4 casos sin contrafactual accionable ni el caso generado pero descartado por implausible.

Dos usos de un mismo contrafactual. Si la clase real del solicitante es 0 (en realidad no habria impagado, falso positivo del modelo), el contrafactual es una [explicacion literal comunicable al cliente](#). Si la clase real es 1 (el modelo acerto al denegar), el contrafactual solo tiene valor de [auditoria interna](#) del comportamiento del modelo y nunca debe presentarse como promesa de aprobacion futura.

ID solicitud	Escenario	Tipo de caso	Estado del CF	Plausible
52346	coste1	Borde umbral	Generado	Si
28495	coste1	Denegacion fuerte	Sin CF accionable	No
10358	coste1	Borde umbral	Generado	Si
79585	coste1	Denegacion fuerte	Sin CF accionable	No
19744	coste10	Borde umbral	Generado	Si
28495	coste10	Denegacion fuerte	Sin CF accionable	No
14183	coste10	Borde umbral	Generado	No
79585	coste10	Denegacion fuerte	Sin CF accionable	No

Que se le dice al cliente -- con contrafactual (id 52346, coste1, falso positivo): el riesgo estimado era del 49,4%, por encima del limite de 49,3% aplicado en este escenario. Reduciendo la utilizacion de credito revolving de 110,3% a 109,3% y elevando los ingresos mensuales de 4.720€ a 5.863€, el riesgo estimado habria bajado al 45,9% y la decision se habria invertido. Se aclara siempre que es una lectura del comportamiento del modelo, no una garantia de aprobacion futura.

Que se le dice al cliente -- sin contrafactual (id 28495, denegacion_fuerte, clase_real=0): el riesgo estimado (83,3%) supera con holgura los umbrales de ambos escenarios; no se hallo una combinacion razonable de cambios en las 4 variables accionables que revirtiera la decision. Esto no significa que la aprobacion sea imposible, sino que el metodo no encontro una alternativa valida bajo las restricciones analizadas.

Matiz metodologico -- caso 14183 (coste10, borde_umbral, clase_real=1). DiCE encuentra tecnicamente una alternativa (ratio de deuda de 1,283 a 0,908 y lineas de credito de 12 a 8, riesgo de 9,1% a 6,5%), pero se descarta por implausible: el valor interno del numero de lineas de credito es fraccionario, no un entero valido. El texto de

cliente ya redondeado (12 a 8) se genera igualmente porque el código condiciona el texto a que exista un contrafactual generado, no a que sea plausible; por eso este caso no debería usarse como explicación real pese a tener un texto aparentemente correcto.

HALLAZGOS

- Solo hay contrafactual accionable en casos **borde_umbral** (4/4 generados); en **denegacion_fuerte**, 0/4. La distancia al umbral condiciona por completo si existe una explicación accionable, no la clase real del solicitante.
- De los 4 generados, 3 son plausibles: 2/2 en `coste1` y 1/2 en `coste10`; el único descartado (id 14183, `coste10`) falla por un conteo no entero en el número de líneas de crédito abiertas.
- La probabilidad de impago media de los 8 casos seleccionados es 0,6843 en `coste1` y 0,4829 en `coste10`: en ambos escenarios se mezclan casos muy cerca del umbral con otros muy por encima (casos 28495 y 79585, `denegacion_fuerte` en los dos escenarios, con probabilidad 0,833 y 0,917 respectivamente).
- La distinción entre explicación al cliente y auditoría interna marca si el contrafactual se puede comunicar como explicación real o si solo sirve para auditar internamente el modelo: con `clase_real=1` (denegación correcta) nunca debe presentarse como promesa de aprobación, aunque el contrafactual exista y sea plausible.

Auditoria: SHAP y cotejo con LIME

Se aplica TreeExplainer -el explicador exacto y rapido pensado para modelos de arboles como el XGBoost de este proyecto- sobre las 21.000 observaciones de test para descomponer, variable a variable, la contribucion a la puntuacion de riesgo, tanto en agregado (importancia global) como para casos individuales denegados (waterfall local). El analisis se repite en los dos escenarios de coste -simetrico y asimetrico- y, ademas, se coteja frente a LIME sobre 6 clientes denegados para contrastar cuanto pesa la estabilidad de cada metodo a la hora de auditar una decision.

0,7873

Importancia media |SHAP| de Revolving (variable nº 1)

2,26x

Margen sobre la 2.ª variable (mora 30-59 dias)

0,0


Diferencia SHAP entre coste1 y coste10 (mismo XGBoost)

0,49

Spearman medio SHAP vs LIME (rango 0,31-0,60)


+0,000112

Margen del caso frontera (id 52346) sobre el umbral




Que mirar: el orden de las variables (de arriba a abajo, mas a menos importante) y el color (rojo = valor alto de la variable, azul = valor bajo) para leer el sentido del efecto.


[RevolvingUtilizationOfUnsecuredLines](#) (uso de credito revolving) domina con 0,7873 de importancia media absoluta, mas del doble -2,26x, no un matiz menor- que la siguiente, [NumberOfTime30-59DaysPastDueNotWorse](#) (0,3486); le siguen [NumberOfTimes90DaysLate](#) (0,3278) y [age](#) (0,2273).




Que mirar: comparar este grafico con el anterior -son identicos-. coste1 y coste10 comparten exactamente el mismo ranking y los mismos valores SHAP (diferencia maxima=0) porque es el mismo XGBoost; solo cambia el umbral de decision aguas abajo (0,4934 en coste1 frente a 0,0906 en coste10).



Que mirar: las barras rojas empujan el score hacia impago, las azules hacia el pago. Caso de borde $id_test=52346$ (coste1, clase real 0): $proba_impago=0,493506$ frente a $umbral=0,493394$, margen de solo $+0,000112$ -una denegacion muy ajustada, casi en el limite exacto de la decision.



Que mirar: el $id_test=28495$ es un caso fuerte presente en ambos escenarios de coste (junto con el id 79585); su explicacion SHAP es identica en coste1 y coste10 (diferencia maxima= $0,0$), evidencia instancia a instancia adicional de que el modelo base no cambia entre escenarios.



Que mirar: la dispersion de los pesos de LIME entre reejecuciones (paneles con barras de error) frente a la linea plana de SHAP, sin varianza, sobre 6 casos denegados seleccionados aparte (3 por escenario), reejecutando LIME 6 veces por caso.

Escenario	Caso (idx)	SD LIME (media)	SD SHAP	Spearman	LIME-SHAP	To
coste1	3665	0,0057	0,0		0,5175	
coste1	11076	0,0055	0,0		0,6014	
coste1	19825	0,0056	0,0		0,3147	
coste10	976	0,0057	0,0		0,5524	
coste10	14834	0,0055	0,0		0,5245	
coste10	17133	0,0058	0,0		0,4266	

Nota tecnica: los valores SHAP de un XGBoost son aditivos en escala log-odds (margen del modelo), no en probabilidad directa; conviene no confundir la magnitud del waterfall con una probabilidad al leerla junto a los umbrales de decision (0,4934 en coste1, 0,0906 en coste10).

HALLAZGOS

- **Revolving domina la importancia global** con $\text{mean_abs_shap}=0,7873$, $2,26\times$ la siguiente variable (NumberOfTime30-59DaysPastDueNotWorse, $0,3486$); le siguen NumberOfTimes90DaysLate ($0,3278$) y age ($0,2273$).
- **coste1 y coste10 comparten ranking y valores SHAP identicos** (diferencia=0) porque es el mismo XGBoost -solo cambia el umbral ($0,4934$ frente a $0,0906$)-, confirmado tambien a nivel de instancia: los casos 28495 y 79585 aparecen en ambos escenarios con SHAP identico (diferencia maxima=0,0).
- SHAP es **exacto y determinista** ($\text{shap_std}=0,0$ en los 6 casos evaluados) mientras LIME fluctua entre reejecuciones (std medio $\sim 0,0056$, hasta $0,0357$); el acuerdo de ranking entre ambos metodos es solo moderado (Spearman medio $\sim 0,49$, rango $0,31-0,60$) y el top-1 coincide en apenas 2 de 6 casos.
- LIME senala **es_centinela_pastdue** como la variable mas inestable en los 6 casos, justo la que SHAP considera casi irrelevante ($\text{mean_abs_shap}=0,0146$, puesto 11 de 12): SHAP es la referencia mas fiable para auditar decisiones individuales.
- El **caso de borde id_test=52346** se decide por un margen minimo ($\text{proba_impago}=0,493506$ frente a umbral= $0,493394$, margen $+0,000112$): es el mismo caso denegado de borde que se explica al cliente en la auditoria de contrafactuales, y una denegacion tan ajustada refuerza por que interesa auditarlo tambien con contrafactuales, ademas de con SHAP.

Otras tecnicas de explicabilidad

Ademas del arbol subrogado (seccion 8) y de SHAP (seccion 10), se aplican de forma independiente cuatro tecnicas de explicabilidad agnosticas al modelo -importancia por permutacion, PDP/ICE, LIME reejecutado y una mini-auditoria de subgrupos por edad- sobre los dos escenarios de coste ya entrenados. Ninguna sustituye a las anteriores: cada una responde a una pregunta distinta -que variable mueve realmente el coste de negocio, como interactuan dos variables entre si, cuan estable es una explicacion local y si la denegacion crece de forma proporcional al riesgo real segun el tramo de edad del solicitante.

0,0888

Rango de P(denegar) por edad con 8 moras (PDP 2D)

3,52x


Denegacion vs impago real, ≤ 30 años (coste10)

2,27x


Ratio minimo, tramo 61-70 años (coste10)

0,0357


Maxima inestabilidad de LIME (peso_std) entre reejecuciones




Que mirar: las 3 barras (permutacion, XGBoost nativo, subrogado) para la misma variable, panel coste1 arriba y coste10 abajo. En coste1 (escenario casi trivial) la permutacion queda casi plana (0,0000-0,0022) mientras XGBoost nativo y el subrogado coinciden en que domina **N. impagos 90+ dias** (0,3301 nativo, 0,7155 subrogado). En coste10, permutacion y subrogado SI coinciden en **Utilizacion de credito revolving** (0,0782 permutacion, 0,4914 subrogado), pero XGBoost nativo sigue puntuando mas alto los impagos 90+ (0,3301, sin cambios): su importancia mide ganancia de impureza global, no esta condicionada al umbral vigente.




Que mirar: el gradiente de color a lo largo del eje edad, comparando la fila sin moras con la fila de 8 moras (maximo del grid). El rango de **P(denegar)** explicado solo por la edad es 0,0448 sin historial de mora frente a 0,0888 con 8 moras -casi el doble-, confirmando con un metodo agnostico independiente del subrogado la interaccion edad x mora de la seccion 8. La superficie es IDENTICA entre coste1 y coste10 (mismo XGBoost): la personalidad distinta esta en el umbral, no en el modelo.



Que mirar: cada linea fina es un cliente (curva ICE al variar solo la utilizacion de credito revolving), la linea gruesa es el promedio (el PDP). La mayoría sube de forma monotonica, pero el punto en que empieza a subir difiere bastante entre clientes: la variable que domina las decisiones en coste10 no actua igual para todos los perfiles de riesgo.



Que mirar: la dispersion (barras de error) del peso que LIME asigna a cada variable entre 6 reejecuciones sobre el mismo caso. La variable centinela de mora (es_centinela_pastdue) tiene, con diferencia, la mayor dispersion: peso_std medio 0,0322 (maximo 0,0357), ~3x mas inestable que la siguiente, N. impagos 90+ dias (std 0,0106). En 9 de 72 combinaciones caso-variable el peso cambia de signo, siempre en variables de relleno del ranking, nunca en las de mayor peso.



Que mirar: compara, tramo a tramo, la barra de tasa de denegacion con la de tasa de impago real. Bajo coste asimetrico el ratio denegacion/impago-real es 3,52x en ≤ 30 años, decrece hasta un minimo de 2,27x en 61-70 años y repunta a 2,49x en los mayores de 70: la denegacion sigue la DIRECCION del riesgo real (baja con la edad) pero no su MAGNITUD, sobre todo en los jovenes.

Tramo de edad	Denegacion coste1	Denegacion coste10	Impago real	Coste m
≤30	0,0397	0,3720	0,1056	
31-40	0,0426	0,2874	0,0895	
41-50	0,0329	0,2371	0,0844	
51-60	0,0178	0,1544	0,0674	
61-70	0,0075	0,0809	0,0356	
>70	0,0054	0,0523	0,0210	

HALLAZGOS

- La importancia a 3 bandas no cuenta la misma historia en los dos escenarios: en coste1 la permutacion queda casi plana (0,0000-0,0022, escenario casi trivial) mientras nativo y subrogado coinciden en N. impagos 90+ dias (0,3301 / 0,7155); en coste10, permutacion y subrogado si coinciden en Utilizacion de credito revolving (0,0782 / 0,4914), porque la importancia por permutacion mide impacto en el coste de las DECISIONES actuales, no ganancia de impureza global.
- El PDP 2D confirma con un metodo agnostico independiente del subrogado que el efecto de la edad sobre P(denegar) es ~2x mayor con historial de mora (rango 0,0448 sin moras vs 0,0888 con 8 moras); la superficie es identica entre escenarios, solo cambia donde corta el umbral.
- LIME reejecutado 6 veces sobre el mismo caso produce pesos distintos: es_centinela_pastdue es la variable mas inestable (peso_std medio 0,0322, maximo 0,0357), justificando preferir SHAP -determinista- como referencia principal de auditoria local.
- Los subgrupos por edad siguen la direccion del riesgo real pero no su magnitud: bajo coste asimetrico el ratio denegacion/impago-real va de 3,52x (≤30 anios) a 2,27x (61-70 anios) y repunta a 2,49x (>70); bajo coste simetrico el mismo patron es mucho mas debil y no monotono, coherente con un escenario donde el modelo apenas aporta valor.

Lectura honesta: el patron por tramo de edad no demuestra discriminacion causal -la edad puede actuar como proxy de variables no observadas (antiguedad crediticia, estabilidad laboral) que el dataset no recoge- y es una auditoria descriptiva, no un

análisis de fairness formal (no se calculan métricas tipo equalized odds). Además, PDP/ICE y la permutación se calculan sobre muestras de 2000-3000 filas, el PDP 2D usa una rejilla de 15x15 puntos y LIME solo se reejecuta sobre 3 casos por escenario: suficiente para ilustrar el problema, no para generalizarlo.

Decisiones de diseno

Esta sección reúne, en una única tabla de trazabilidad, las quince decisiones técnicas más relevantes del proyecto -desde el paradigma de modelado hasta la profundidad del árbol subrogado-, cada una con la evidencia numérica que la sostiene. A diferencia del resto del informe, aquí sí se cita el identificador de cada decisión porque esta sección es precisamente su catálogo de referencia; el identificador es secundario, cada fila se explica por sí sola. Dos hallazgos transversales sostienen buena parte del preprocesado: la corrección del numerador corrupto de **DebtRatio** y el colapso de la multicolinealidad al tratar los códigos centinela 96/98 como valores ausentes.

15

Decisiones documentadas

0

Máx. diferencia OOF entre
escenarios

7279

Solicitantes que pasan a
denegado en producción

1.91

VIF máximo tras tratar los
centinelas

Catálogo de las 15 decisiones

ID	Decisión
D-0.1	Supervisado vs. bandit contextual
D-0.2	Un modelo con dos umbrales vs. dos modelos por escenario
D-0.3	Familia de modelo (lineal / red neuronal / árboles / bandit)
D-1.1	Imputación de nulos (MonthlyIncome, NumberOfDependents)
D-1.2	Outliers y cola de DebtRatio Recálculo
D-1.4	División train/test
D-1.6	Filas duplicadas
D-2.1	Protocolo de validación (umbral y familia)
D-3.1	Umbral analítico vs. empírico
D-3.2	Coste del escenario 2
D-5.1	Complejidad del árbol subrogado
D-6.1	Herramienta de contrafactuales
D-6.2	Número de casos contrafactuales
D-7.1	Instancias y explicador para SHAP local
D-8.1	Técnicas XAI adicionales (cuaderno 08)

La columna **ID** es una referencia secundaria de trazabilidad interna del proyecto: cada fila se entiende por sí sola con el número de evidencia al lado, sin necesidad de consultar ningún documento externo.

Evidencia central: DebtRatio y colapso de la multicolinealidad

Bloque	Métrica	Antes	Después
DebtRatio	Mediana en la cola (> percentil 97.5)	1152	0.29
DebtRatio	KS entre la cola y la distribución sana	0.9284	0.1671
DebtRatio	AUC univariante frente al target	0.5212	0.5531
VIF PastDue 30-59	Factor de inflación de varianza	40.9	~1.18
VIF PastDue 60-89	Factor de inflación de varianza	71.7	~1.15
VIF PastDue 90+	Factor de inflación de varianza	89.6	~1.17

HALLAZGOS

- El modelo ganador (XGBoost) lo es por capacidad, no por paradigma: bate a la regresión logística y al bandit LinUCB con un coste de test de 0.0634 en el escenario simétrico y 0.3275 en el asimétrico.
- Un único modelo sirve para los dos escenarios de negocio: las probabilidades OOF son idénticas byte a byte (diferencia máxima = 0); solo cambia el umbral de decisión, de 0.4934 a 0.0906.
- El escenario 2 es asimétrico ($C_{FN} = 10 \times C_{FP}$, errata del enunciado confirmada por el profesor) y su impacto es material: 7279 solicitantes del conjunto de producción cambian de decisión respecto a asumir coste simétrico.
- Recalcular DebtRatio con el ingreso ya imputado, en vez de winsorizar a ciegas, es la aportación analítica central del preprocesado: el KS entre la cola contaminada y la distribución sana baja de 0.9284 a 0.1671 y el AUC univariante mejora de 0.5212 a 0.5531.
- Tratar los centinelas 96/98 como valores ausentes colapsa la multicolinealidad de las tres columnas de mora: el VIF máximo del conjunto completo tras el cambio es 1.91, muy por debajo del umbral de alerta habitual de 5.
- El árbol subrogado revela dos personalidades de riesgo según el escenario de coste: el F1 de la clase «denegar» sube de 0.756 (simétrico) a 0.844 (asimétrico); SHAP, en cambio, es idéntico entre escenarios porque comparten el mismo XGBoost -solo cambia el umbral que traduce la puntuación de riesgo en decisión.
- Las técnicas de explicabilidad adicionales (D-8.1) usan distintos tamaños de muestra por coste computacional: 2000 filas para PDP/ICE, 3000 filas con 10 repeticiones para la importancia por permutación y 6 reejecuciones por caso para medir la inestabilidad de LIME.

Reflexion final

El mismo XGBoost, sin reentrenar y con las mismas probabilidades OOF byte a byte, cambia de **politica de riesgo** -no de modelo- al desplazar el umbral de decision de 0.4934 a 0.0906. El AUC de test es identico en los dos escenarios (0.8701), la confirmacion cuantitativa de que se trata del mismo estimador re-umbralizado. Esta seccion no ejecuta analisis nuevo: relee criticamente los notebooks 02 a 12 y reorganiza sus hallazgos numericos alrededor de las cuatro preguntas del enunciado.

0.8701

AUC test (identico en ambos escenarios)

0.0906

Umbral asimetrico (analitico $1/11=0.0909$)

0.3275

Coste medio test, escenario asimetrico

51.01%

Mejora vs "conceder a todos" (asimetrico)

x27

Gap CV XGBoost-logistica: 0.000631 -> 0.016988

3.52x

Denegacion vs impago real, solicitantes ≤ 30 anios

1. Cambio de comportamiento optimo

Mover el umbral de 0.4934 a 0.0906 -ambos casi identicos a sus umbrales analiticos teoricos, 0.5 y $1/11=0.0909$, senal de buena calibracion- desplaza la tasa de denegacion en test de 2.38% a 18.70%, y en produccion de 2.36% a 18.53% (x7.9). El coste medio en test pasa de 0.0634 a 0.3275, y la mejora frente a "conceder a todos" escala de 5.20% a 51.01%. En produccion, **7279 solicitantes** pasan de concedido a denegado entre el escenario simetrico y el asimetrico, y **0** se mueven en sentido inverso: el desplazamiento del umbral es estrictamente mas restrictivo, nunca libera credito que antes se denegaba.

Escenario	Umbral optimo	Denegacion test	Denegacion produccion
Simetrico ($C_{FP}=C_{FN}=1$)	0.4934	2.38%	2.36%
Asimetrico ($C_{FN}=10 \cdot C_{FP}$)	0.0906	18.70%	18.53%

2. Trade-off entre rendimiento y explicabilidad

En el escenario simetrico, **XGBoost** apenas mejora a un modelo lineal (gap de validacion cruzada logistica-XGBoost de solo 0.000631) y la mejora frente a conceder-todo es marginal (5.20%): una curva de coste casi plana alrededor del optimo. En el escenario asimetrico el gap crece a 0.016988 -unas **27 veces mayor**- y la mejora sube a 51.01% : aqui el modelo aporta valor real de negocio y es donde pagar el coste de opacidad de XGBoost frente a un modelo lineal se justifica. Esa opacidad se audita con cuatro tecnicas independientes -arbol subrogado, contrafactuales, SHAP/LIME y subgrupos por edad- porque ninguna es suficiente por si sola: cada una cubre una pregunta distinta (aproximacion global, accionabilidad individual, atribucion local, equidad).

La opacidad adicional de un modelo de boosting frente a uno lineal solo se justifica cuando el coste de negocio es asimetrico: con costes simetricos la diferencia de rendimiento esta dentro del ruido.

3. Lecciones de la auditoria: fiabilidad y calidad de la explicacion

El arbol subrogado tiene "dos personalidades": en el escenario simetrico domina el numero de impagos a 90+ dias (importancia 0.7155); en el asimetrico domina la utilizacion de credito revolving (0.4914). Un arbol degenerado de una sola regla llega a fidelidad global alta pero con **fid_denegar=0%** en los dos escenarios -no sirve como explicacion en ninguno-, mientras que el arbol operativo real sube esa fidelidad a 78.96% ($F1=0.7562$) en el simetrico y a 84.54% ($F1=0.8439$) en el asimetrico: mejor precisamente donde mas importa. Los contrafactuales de DiCE solo se generan en 4 de 8 casos analizados (0 de 4 en denegaciones fuertes) y, de esos 4 generados, solo 3 son plausibles -poco accionables justo donde mas se necesitaria explicar al cliente por que se le deniega-. SHAP es determinista (desviacion estandar 0 entre reejecuciones) mientras que LIME es inestable (desviacion media 0.0056 , maxima 0.0357) y cambia de signo en variables de menor peso; el acuerdo de ranking entre ambos metodos, medido con Spearman, es de solo ~ 0.49 , con el top-1 coincidiendo en apenas 2 de 6 casos.

El sesgo por edad observado ($3.52x$ en menores de 30 anios frente a $2.27x$ - $2.49x$ en tramos mayores) no demuestra discriminacion causal: la edad puede actuar como proxy de factores no observados -antigüedad crediticia, estabilidad laboral- que el dataset no recoge.

4. Limitaciones y lineas de mejora

El coste real en produccion no se puede verificar porque las etiquetas de impago estan ocultas; solo la tasa de denegacion es medible directamente, y ya muestra el mismo salto que en test (2.36% a 18.53%). La recalibracion de DebtRatio introduce un

acoplamiento debil pero real con la edad -la correlacion de Spearman pasa de +0.0289 a -0.0981 tras la recalibracion, Pearson practicamente nulo (-0.0059)-, declarado explicitamente como un coste honesto de la transformacion. Esa recalibracion se verifico como libre de fuga de informacion entre train y test de forma independiente: la media de la variable escalada es $\sim 6.83e-16$ en train frente a 0.021086 en test y 0.014083 en produccion, un salto de unos 14 ordenes de magnitud. Se detecto ademas una limitacion de ingenieria al reproducir resultados: cargar el modelo guardado con una version de XGBoost distinta a la del entrenamiento reconstruye mal un parametro interno (base_score) e infla las probabilidades por un factor ~ 5 -la denegacion pasaria de 2.4%/18.7% a cifras cercanas a 25%/85%- , corregido fijando la version exacta de la libreria en las dependencias del proyecto.

HALLAZGOS

- Un unico modelo (XGBoost) con dos umbrales cubre los dos escenarios de negocio: AUC de test identico (0.8701) y probabilidades OOF identicas byte a byte entre `coste1` y `coste10`.
- El valor del modelo escala con la asimetria del coste: la mejora frente a conceder-todo pasa de 5.20% a 51.01%, y el gap frente a un modelo lineal crece de 0.000631 a 0.016988 ($\sim \times 27$).
- La auditoria multi-tecnica revela que la fiabilidad de la explicacion depende del par umbral-tecnica: fidelidad del subrogado 78.96% $\rightarrow$ 84.54%, DiCE solo genera contrafactuales accionables en 4 de 8 casos, y SHAP-LIME solo concuerdan a Spearman ~ 0.49 .
- Proximos pasos: monitorizar el umbral 0.0906 cuando lleguen etiquetas reales de produccion, ampliar la auditoria de subgrupos a otros atributos protegidos, relajar las restricciones de accionabilidad de DiCE para denegaciones fuertes, y sustituir o estabilizar LIME frente a SHAP.